

**UNIVERSIDAD NACIONAL DE INGENIERÍA
FACULTAD DE INGENIERÍA INDUSTRIAL Y DE
SISTEMAS
SECCIÓN DE POSGRADO**



TESIS

**“OPTIMIZACIÓN TOPOLÓGICA DE PUENTES
RETICULADOS ASISTIDA POR APRENDIZAJE
AUTOMÁTICO Y ALGORITMOS DE
OPTIMIZACIÓN BIOINSPIRADA”**

**PARA OPTAR EL GRADO ACADÉMICO DE:
MAESTRÍA EN INTELIGENCIA ARTIFICIAL**

ELABORADO POR:

Deiby Estacio Sánchez

DOCENTE:

Glen Dario Rodriguez Rafael

**LIMA – PERÚ
DICIEMBRE 2025**

DEDICATORIA

A mi madre, **Luz Bet Sánchez Villalobos**, por su amor incondicional, su infinita paciencia y su fortaleza constante.

Por ser mi mayor inspiración, por acompañarme en cada etapa de mi vida y por creer en mí incluso en los momentos más difíciles. Este logro es también suyo.

AGRADECIMIENTOS

Deseo expresar mi más profundo agradecimiento, en primer lugar, a mi madre, **Luz Bet Sánchez Villalobos**, por su apoyo incondicional, su fortaleza, paciencia y motivación constante a lo largo de toda mi formación académica. Su ejemplo de perseverancia y amor ha sido fundamental para culminar con éxito este trabajo de investigación.

Asimismo, agradezco al docente **Glen Dario Rodriguez Rafael**, por su orientación, dedicación y valiosos aportes académicos, los cuales contribuyeron significativamente al desarrollo y culminación de esta tesis.

Finalmente, extendo mi gratitud a la Universidad Nacional de Ingeniería, a la Facultad de Ingeniería Industrial y de Sistemas y a la Maestría en Inteligencia Artificial, por brindarme la formación académica y los recursos necesarios para mi desarrollo profesional.

Índice general

1. INTRODUCCIÓN	6
1.1. Formulación del problema	9
1.1.1. Problema general	10
1.1.2. Problemas específicos	10
1.2. Justificación de la investigación	11
1.3. Objetivos	12
1.3.1. Objetivo general	12
1.3.2. Objetivos específicos	12
1.4. Hipótesis General	13
1.4.1. Hipotesis específicas	13
1.5. Matriz de convergencia	14
1.6. Alcances y delimitaciones	16
1.6.1. Alcances de la Investigación	16
1.6.2. Delimitaciones de la Investigación	17
2. MARCO TEÓRICO Y ESTADO DEL ARTE	18
2.1. Puentes reticulados	18
2.1.1. Evolución histórica y fundamentos estructurales	19
2.1.2. Tipologías estructurales de puentes reticulados	23
2.2. Optimización topológica	27
2.2.1. Evolución y fundamentos conceptuales	28
2.2.2. Optimización topológica continua y discreta	28
2.3. Optimización bioinspirada	32
2.3.1. Fundamentos conceptuales de la optimización bioinspirada	33
2.3.2. Clasificación de algoritmos bioinspirados	33
2.3.3. Optimización bioinspirada en ingeniería estructural	35
2.4. Particle Swarm Optimization (PSO)	36
2.5. Aprendizaje automático en ingeniería estructural	39
2.6. Graph Neural Networks (GNN)	41

2.7.	Método de Elementos Finitos	43
2.7.1.	Elemento finito tipo Frame	45
2.7.2.	Elemento finito tipo shell	46
2.8.	Modelo Paramétrico Computacional	46
2.9.	Estado del arte	48
3.	FORMULACIÓN DEL PROBLEMA	51
3.1.	Variables de diseño	51
3.2.	Variables geométricas	51
3.3.	Variables de sección transversal	52
3.4.	Vector de variables de diseño	52
3.5.	Implementación computacional	52
3.6.	Función objetivo	53
3.7.	Restricciones	53
3.7.1.	Restricciones de resistencia	53
3.7.2.	Restricciones de servicio	54
3.7.3.	Restricciones de estabilidad	54
4.	METODOLOGÍA PROPUESTA	55
4.1.	Modelamiento Paramétrico con Rhino–Grasshopper	55
4.1.1.	Parametrización de la geometría del puente	56
4.1.2.	Integración paramétrica con el modelo de elementos finitos	59
4.1.3.	Ingeniería Estructural y Normatividad.	61
4.1.4.	Importancia Operativa	64
4.1.5.	Solicitaciones	67
4.1.6.	DESPLAZAMIENTOS PARA EFECTOS SÍSMICOS	81
4.1.7.	DEFLEXIONES POR CARGA VIVA	82
4.1.8.	IDENTIFICACION DE SECCIONES Y ETIQUETAS DEL MO- DELO	83
4.1.9.	DIAGRAMA DE FUERZAS	84
4.1.10.	DISEÑO DE ELEMENTOS METÁLICOS	88
4.1.11.	Desarrollo e implementación de modelo DNN y PSO aplicado a la optimización Topológica del puente.	95
5.	RESULTADOS Y DISCUSIÓN	109
6.	CONCLUSIONES Y RECOMENDACIONES	110
6.1.	Conclusiones	110
6.2.	Recomendaciones	111

Capítulo 1

INTRODUCCIÓN

El diseño estructural de puentes reticulados metálicos constituye una de las aplicaciones más representativas de la ingeniería estructural moderna, debido a su elevada eficiencia mecánica, su adaptabilidad geométrica y su capacidad para cubrir luces medias y grandes mediante mecanismos resistentes predominantemente axiales. Estas características han consolidado su uso a nivel internacional como una solución técnica idónea para contextos donde se requiere optimizar el desempeño estructural bajo restricciones severas de peso propio, logística constructiva y condiciones geotécnicas desfavorables [1, 2].

En el contexto peruano, los puentes reticulados metálicos representan una tipología estructural estratégica para el desarrollo de la infraestructura vial, particularmente en zonas rurales, amazónicas y altoandinas, donde la complejidad topográfica, la limitada capacidad portante del suelo y las restricciones de acceso dificultan la ejecución de superestructuras de concreto de gran masa. Entidades como el Ministerio de Transportes y Comunicaciones (MTC), Provías Nacional y los Gobiernos Regionales han promovido históricamente el uso de este tipo de puentes para luces comprendidas, en la práctica, entre 55 m y 100 m, siendo recurrentes los diseños para luces de 60 m, 70 m y 80 m.

No obstante, pese a su importancia estratégica, el proceso de diseño estructural de puentes reticulados metálicos en el Perú se encuentra dominado por enfoques tradicionales de carácter determinista y prescriptivo. En la práctica profesional, la definición de la topología estructural entendida como la disposición, conectividad y jerarquía resistente de los elementos se realiza generalmente en las etapas preliminares del proyecto mediante criterios empíricos, experiencia previa del proyectista y tipologías convencionales ampliamente difundidas, como los sistemas Warren, Pratt o Howe. Estas configuraciones suelen adoptarse sin una evaluación sistemática de alternativas topológicas equivalentes que puedan ofrecer un mejor desempeño estructural global.

La geometría del reticulado, incluyendo la altura de la celosía, la longitud de los

paneles y la disposición de diagonales, se establece habitualmente a partir de relaciones simplificadas del tipo $L/8$ a $L/12$, recomendadas por la práctica tradicional, sin que exista un proceso formal de exploración del espacio de diseño. Como resultado, la topología estructural queda prácticamente fijada desde el inicio del proyecto, limitando el diseño posterior a un proceso iterativo de ajuste de secciones transversales para cumplir con las verificaciones normativas de resistencia, estabilidad y servicio exigidas por especificaciones como AASHTO LRFD.

Desde un punto de vista metodológico, este enfoque presenta limitaciones significativas. El diseño de un puente reticulado metálico constituye inherentemente un problema de optimización topológica discreta, caracterizado por un espacio de búsqueda altamente combinatorio, no convexo y de gran dimensionalidad, en el cual la presencia o ausencia de elementos estructurales, así como su conectividad, condicionan de manera decisiva el flujo de esfuerzos, la rigidez global, el comportamiento dinámico y la redundancia estructural. Los métodos clásicos de diseño, orientados principalmente a la verificación secuencial de secciones, resultan insuficientes para abordar de manera eficiente este tipo de problemas.

En la práctica profesional, el número de configuraciones topológicas evaluadas rara vez supera una o dos alternativas, lo cual impide aproximarse al óptimo global del problema de diseño. Esta restricción no responde únicamente a una falta de herramientas computacionales, sino principalmente al elevado costo operativo y computacional asociado a la evaluación estructural exhaustiva de múltiples alternativas mediante análisis de elementos finitos (FEM), especialmente cuando se consideran múltiples combinaciones de carga, estados límite últimos y de servicio, criterios de fatiga, requisitos de estabilidad global y verificaciones normativas adicionales.

Como consecuencia de este enfoque limitado, numerosos expedientes técnicos de puentes reticulados metálicos ejecutados en el Perú evidencian un patrón recurrente de sobredimensionamiento estructural. En particular, el peso de acero de la superestructura suele situarse en rangos comprendidos entre 90 y 140 kg/m² de tablero, valores que superan de manera consistente los rangos reportados en la literatura especializada para estructuras de luces similares diseñadas mediante enfoques de optimización topológica, los cuales pueden situarse entre 70 y 100 kg/m² [3, 4].

Este exceso de material, del orden del 15 % al 30 %, no obedece necesariamente a mayores exigencias normativas de seguridad, servicio o durabilidad, sino a la incapacidad del proceso tradicional para identificar configuraciones estructurales más eficientes desde una perspectiva global.

Desde una visión más amplia, resulta fundamental precisar que la optimización estructural no puede reducirse a la minimización del peso. Un diseño verdaderamente

optimizado debe garantizar simultáneamente el cumplimiento estricto de las normativas vigentes, niveles adecuados de rigidez y confort estructural, control de deformaciones y vibraciones, redundancia y robustez frente a fallas locales, durabilidad, facilidad constructiva y calidad formal. Sin embargo, el enfoque tradicional tiende a priorizar la seguridad mediante sobredimensionamiento, sacrificando eficiencia material, racionalidad estructural y calidad integral del diseño.

Las implicancias económicas de este sobredimensionamiento son significativas. Considerando costos de acero estructural instalado en el Perú del orden de USD 2 500 a USD 3 500 por tonelada, un exceso típico de entre 50 y 150 toneladas de acero en un puente reticulado de mediana luz puede generar sobre costos directos comprendidos entre USD 125 000 y USD 525 000 por proyecto, sin considerar los efectos indirectos sobre el diseño de subestructuras, cimentaciones y procesos constructivos.

Asimismo, el tiempo total requerido para el diseño estructural de un puente reticulado metálico de 55 m a 100 m de luz suele extenderse entre tres y seis meses, una parte considerable de los cuales se destina a retrabajos, ajustes manuales y correcciones derivadas de observaciones técnicas. Este plazo contrasta de manera evidente con la capacidad de los sistemas computacionales actuales, que permiten ejecutar análisis estructurales complejos en escalas de horas, revelando una ineficiencia metodológica sustancial en el proceso de diseño.

Desde una perspectiva sistémica, esta situación pone en evidencia una brecha crítica entre el estado del arte en optimización estructural y su aplicación efectiva en la práctica profesional del diseño de puentes en el Perú. Si bien existen herramientas avanzadas de análisis y modelación, estas se emplean fundamentalmente como instrumentos de verificación y no como plataformas de exploración y optimización del espacio de diseño. En consecuencia, las decisiones topológicas continúan sustentándose en heurísticas, con escaso respaldo cuantitativo en términos de eficiencia estructural global.

Adicionalmente, la ausencia de criterios explícitos de optimización topológica tiene implicancias no solo técnicas y económicas, sino también formales y funcionales. Muchos puentes reticulados diseñados bajo enfoques tradicionales presentan configuraciones con alta densidad de barras, escasa jerarquización resistente y limitada claridad estructural, lo que afecta la calidad integral de la infraestructura y su integración con el entorno, aspectos cada vez más relevantes en la ingeniería de puentes contemporánea.

En este contexto, el problema central que aborda la presente investigación radica en la ausencia de una metodología computacional integrada que permita optimizar de manera sistemática la topología de puentes reticulados metálicos, considerando simultáneamente criterios de desempeño estructural, cumplimiento normativo, eficiencia computacional y calidad global del diseño. La complejidad inherente del problema

justifica la adopción de algoritmos de optimización bioinspirada, capaces de explorar espacios de búsqueda discretos y no convexos, asistidos por modelos de aprendizaje automático orientados a reducir el número de análisis FEM requeridos. Este enfoque se plantea como una alternativa técnicamente viable y metodológicamente necesaria para modernizar el proceso de diseño de puentes reticulados en el contexto peruano.

1.1. Formulación del problema

El proceso de diseño estructural de puentes reticulados metálicos se ha desarrollado tradicionalmente mediante enfoques deterministas, en los cuales la topología estructural se define en etapas tempranas del proyecto a partir de configuraciones convencionales y permanece invariable durante el resto del proceso de diseño. Bajo este esquema, el diseño se centra principalmente en la verificación de los estados límite de resistencia y servicio mediante ajustes iterativos de secciones, sin considerar la topología como una variable activa de optimización [1].

Desde el punto de vista de la optimización estructural, el diseño de un puente reticulado puede formularse como un problema de optimización topológica discreta, en el cual la presencia o ausencia de elementos estructurales determina la conectividad, rigidez global y distribución de esfuerzos de la estructura. Este tipo de problemas se caracteriza por un espacio de búsqueda altamente combinatorio, no convexo y de gran dimensión, lo que imposibilita su resolución mediante métodos deterministas clásicos o técnicas basadas en gradientes [6].

En la práctica profesional, la imposibilidad de explorar sistemáticamente dicho espacio de soluciones conduce a la evaluación de un número muy limitado de configuraciones topológicas, generalmente una o dos alternativas. Como consecuencia, las soluciones adoptadas suelen encontrarse alejadas del óptimo global, presentando sobredimensionamiento estructural y baja eficiencia en el uso del material. Estudios previos han demostrado que la optimización topológica de estructuras reticuladas puede generar reducciones significativas en el peso estructural sin comprometer el desempeño resistente ni el cumplimiento normativo [3, 4].

Adicionalmente, la evaluación estructural de cada configuración topológica mediante métodos de elementos finitos (FEM) implica un costo computacional considerable, especialmente cuando se consideran múltiples combinaciones de carga y verificaciones normativas. Esta limitación computacional restringe la aplicación práctica de algoritmos de optimización global basados en análisis estructural directo, incrementando el tiempo total de diseño y reduciendo la viabilidad de enfoques exhaustivos [2].

Desde una perspectiva metodológica, esta problemática evidencia la ausencia de

un marco computacional integrado que permita combinar de manera eficiente la exploración del espacio topológico con la evaluación estructural automatizada. En los últimos años, diversos autores han señalado la necesidad de incorporar algoritmos de optimización bioinspirada, tales como el Particle Swarm Optimization (PSO), debido a su capacidad para manejar variables discretas y espacios de búsqueda complejos sin requerir información de gradientes [7]

No obstante, la aplicación directa de estos algoritmos en problemas estructurales de gran escala sigue estando limitada por el elevado número de evaluaciones FEM requeridas. En este contexto, el uso de modelos de aprendizaje automático como modelos sustitutos (surrogate models) ha emergido como una alternativa viable para aproximar el comportamiento estructural y reducir significativamente el costo computacional del proceso de optimización [5]. En particular, las Graph Neural Networks (GNN) han demostrado ser especialmente adecuadas para representar estructuras reticuladas, al modelar de forma explícita la relación entre nodos y elementos estructurales.

En consecuencia, el problema central que aborda la presente investigación se relaciona con la falta de una metodología computacional integrada que permita optimizar la topología de puentes reticulados metálicos de manera sistemática, eficiente y verificable, combinando algoritmos de optimización bioinspirada con modelos de aprendizaje automático, y garantizando simultáneamente el cumplimiento de los criterios normativos de diseño estructural. La formulación del problema se orienta, por tanto, a superar las limitaciones del enfoque tradicional y a establecer un marco metodológico que mejore la eficiencia estructural y computacional del diseño de puentes reticulados.

1.1.1. Problema general

¿Cómo desarrollar e implementar una metodología computacional que permita optimizar la topología de puentes reticulados metálicos, minimizando el peso estructural y el costo computacional del análisis, mediante la integración de algoritmos de optimización bioinspirada y modelos de aprendizaje automático, garantizando el cumplimiento de los criterios normativos de diseño estructural?

1.1.2. Problemas específicos

- ¿Cómo formular el problema de optimización topológica de puentes reticulados como un problema discreto que considere la presencia o ausencia de elementos estructurales bajo restricciones de resistencia y servicio?
- ¿Cómo aplicar un algoritmo de optimización bioinspirada, como el PSO, para explorar de manera eficiente el espacio de configuraciones topológicas posibles

sin recurrir a búsquedas exhaustivas?

- ¿Cómo integrar modelos de aprendizaje automático, en particular Graph Neural Networks, como modelos sustitutos del análisis estructural para reducir el número de evaluaciones FEM requeridas?
- ¿En qué medida la metodología propuesta mejora la eficiencia estructural y computacional del proceso de diseño de puentes reticulados en comparación con el enfoque tradicional?

1.2. Justificación de la investigación

La presente investigación se justifica por la necesidad de modernizar y mejorar el proceso de diseño estructural de puentes reticulados metálicos, superando las limitaciones inherentes a los enfoques tradicionales basados en tipologías fijas y procedimientos iterativos de verificación. En particular, el diseño convencional no incorpora de manera sistemática la topología estructural como una variable activa de optimización, lo que conduce frecuentemente a soluciones sobredimensionadas, con bajo aprovechamiento del material y limitada eficiencia estructural global.

Desde una justificación técnica, la investigación propone una metodología que integra modelado paramétrico, análisis estructural automatizado y optimización computacional, permitiendo explorar de manera sistemática un amplio conjunto de configuraciones estructurales. Para ello, se hace uso de Rhino–Grasshopper como plataforma de modelado paramétrico, la cual permite definir la geometría del puente reticulado mediante parámetros controlables y generar múltiples configuraciones topológicas de forma automática. Este enfoque resulta especialmente adecuado para problemas de optimización topológica, donde la variabilidad geométrica y la conectividad estructural desempeñan un rol fundamental en el desempeño global de la estructura.

Las configuraciones estructurales generadas paramétricamente son sometidas a análisis estructural mediante el método de los elementos finitos (FEM), garantizando una evaluación rigurosa del comportamiento resistente y de servicio conforme a los criterios normativos de diseño. La automatización de este proceso permite reducir significativamente la intervención manual del proyectista, minimizando errores y asegurando la consistencia en la evaluación de las distintas alternativas estructurales.

Desde una justificación científica, la investigación contribuye al desarrollo de enfoques híbridos que combinan algoritmos de optimización bioinspirada con modelos de aprendizaje automático, aplicados a problemas reales de ingeniería estructural. La integración de estas técnicas permite abordar problemas de optimización topológica

discreta, caracterizados por espacios de búsqueda no convexos y altamente combinatorios, los cuales resultan difíciles de resolver mediante métodos deterministas clásicos. En este sentido, la investigación aporta conocimiento en la aplicación de técnicas avanzadas de optimización y aprendizaje automático al diseño de puentes reticulados, un campo aún poco explorado en el contexto latinoamericano.

Desde una justificación metodológica, el uso de modelado paramétrico mediante Grasshopper permite establecer un flujo de trabajo reproducible y escalable, en el cual la generación de geometrías, la evaluación estructural y el proceso de optimización se encuentran integrados en un único entorno computacional. Este enfoque facilita la comparación objetiva entre distintas configuraciones topológicas y permite cuantificar de manera directa el impacto de la optimización en términos de peso estructural, distribución de esfuerzos y eficiencia global.

Finalmente, desde una justificación académica, la investigación se alinea con las tendencias actuales de la ingeniería estructural computacional, promoviendo el uso de herramientas avanzadas de modelado paramétrico, análisis numérico y optimización asistida por inteligencia artificial. El desarrollo de esta tesis contribuye a fortalecer la formación investigativa en el ámbito de la ingeniería estructural y establece un marco metodológico que puede ser extendido a otras tipologías estructurales y problemas de diseño avanzado.

1.3. Objetivos

1.3.1. Objetivo general

Desarrollar e implementar una metodología computacional integrada para la optimización topológica de puentes reticulados metálicos, que permita mejorar la eficiencia estructural y computacional del proceso de diseño mediante el uso de algoritmos de optimización bioinspirada y modelos de aprendizaje automático, garantizando el cumplimiento de los criterios normativos de resistencia y servicio.

1.3.2. Objetivos específicos

- Formular matemáticamente el problema de optimización topológica de puentes reticulados metálicos como un problema discreto, considerando variables binarias asociadas a la presencia o ausencia de elementos estructurales, así como restricciones de resistencia, servicio y conectividad estructural.
- Implementar un algoritmo de optimización bioinspirada, basado en Particle Swarm

Optimization (PSO), que permita explorar de manera eficiente el espacio de configuraciones topológicas posibles, evitando la convergencia prematura a soluciones subóptimas.

- Integrar modelos de aprendizaje automático, específicamente Graph Neural Networks (GNN), como modelos sustitutos del análisis estructural, con el fin de reducir el número de evaluaciones mediante métodos de elementos finitos (FEM) requeridas durante el proceso de optimización topológica.
- Evaluar comparativamente la metodología propuesta frente al enfoque tradicional de diseño de puentes reticulados, cuantificando las mejoras obtenidas en términos de eficiencia estructural (peso de la superestructura) y eficiencia computacional (tiempo de análisis y número de evaluaciones FEM).

1.4. Hipótesis General

La aplicación de una metodología computacional integrada que combine optimización bioinspirada mediante Particle Swarm Optimization (PSO) y modelos de aprendizaje automático basados en Graph Neural Networks (GNN) permite optimizar la topología de puentes reticulados metálicos, logrando una reducción del peso estructural total entre 15 % y 30 %, una disminución del número de evaluaciones FEM superior al 60 %, y una reducción del tiempo computacional global del proceso de diseño entre 40 % y 70 %, en comparación con el enfoque tradicional de diseño, manteniendo el cumplimiento de los criterios normativos de resistencia y servicio.

1.4.1. Hipotesis específicas

- La formulación del diseño de puentes reticulados metálicos como un problema de optimización topológica discreta, empleando variables binarias asociadas a la presencia o ausencia de elementos estructurales e incorporando restricciones de resistencia y servicio, permite representar adecuadamente el comportamiento estructural global del sistema y viabiliza la generación y evaluación de más de 100 a 10000 configuraciones topológicas sin comprometer la consistencia normativa.
- La aplicación del algoritmo Particle Swarm Optimization (PSO) permite explorar de manera eficiente el espacio de configuraciones topológicas, obteniendo soluciones con reducciones de peso estructural entre 15 % y 25 % respecto a una topología inicial convencional, convergencia del algoritmo en menos de 100 iteraciones, sin

recurrir a búsquedas exhaustivas que resultarían computacionalmente inviables para el tamaño del problema.

- La integración de Graph Neural Networks (GNN) como modelos sustitutos del análisis estructural permite reducir el número de evaluaciones mediante métodos de elementos finitos (FEM) en al menos un 20 %, manteniendo un error relativo promedio inferior al 5 % en la predicción de variables estructurales clave, tales como desplazamientos máximos y fuerzas internas críticas.
- Evaluar comparativamente la metodología propuesta frente al enfoque tradicional de diseño de puentes reticulados, cuantificando las mejoras obtenidas en términos de eficiencia estructural (peso de la superestructura) y eficiencia computacional (tiempo de análisis y número de evaluaciones FEM).

1.5. Matriz de convergencia

Cuadro 1.1: Matriz de consistencia de la investigación

Problemas de investigación	Objetivos	Hipótesis	Variables	Indicadores / Medios de verificación
Problema general	Objetivo general	Hipótesis general	Variable independiente	Indicadores
La ausencia de una metodología computacional integrada para optimizar la topología de puentes reticulados metálicos conduce a soluciones sobredimensionadas, con baja eficiencia estructural y elevado costo computacional en el proceso de diseño.	Desarrollar e implementar una metodología computacional integrada para la optimización topológica de puentes reticulados metálicos mediante algoritmos de optimización bioinspirada y aprendizaje automático, garantizando el cumplimiento normativo.	La metodología basada en PSO asistido por GNN permite reducir el peso estructural entre 15 % y 30 % y el costo computacional del análisis entre 40 % y 70 %, manteniendo el cumplimiento de los criterios normativos de resistencia y servicio.	Metodología computacional integrada (PSO + GNN). Variable dependiente Eficiencia estructural y computacional del diseño.	■ Peso estructural total (kg) ■ Tiempo computacional total (horas/días) ■ Número de evaluaciones FEM ■ Verificación normativa

Cuadro 1.2: Matriz de consistencia de los problemas específicos

Problemas específicos	Objetivos específicos	Hipótesis específicas	Variables	Indicadores / Medios de verificación
PE1	OE1	HE1	Variables de diseño	Indicadores
¿Cómo formular el problema de optimización topológica de puentes reticulados como un problema discreto que considere la presencia o ausencia de elementos estructurales bajo restricciones de resistencia y servicio?	Formular matemáticamente el problema de optimización topológica como un problema discreto, empleando variables binarias y restricciones de resistencia y servicio.	La formulación discreta permite evaluar entre 100 y 10000 configuraciones topológicas cumpliendo los estados límite de resistencia y servicio.	Variables de diseño binarias (0–1).	■ Número de configuraciones generadas ■ Cumplimiento de estados límite ■ Conectividad estructural válida
PE2	OE2	HE2	Algoritmo PSO	Indicadores
¿Cómo aplicar un algoritmo de optimización bioinspirada, como el PSO, para explorar eficientemente el espacio topológico sin recurrir a búsquedas exhaustivas?	Aplicar el algoritmo PSO para explorar de manera eficiente el espacio de configuraciones topológicas posibles.	El PSO permite obtener configuraciones con reducciones de peso entre 15 % y 25 % respecto a la topología inicial en menos de 100 iteraciones.	Algoritmo PSO (parámetros ω , c_1 , c_2).	■ Peso estructural final (kg) ■ Iteraciones hasta convergencia ■ Historial de convergencia
PE3	OE3	HE3	Modelo GNN	Indicadores
¿Cómo integrar modelos de aprendizaje automático, en particular GNN, como modelos sustitutos del análisis estructural para reducir evaluaciones FEM?	Integrar Graph Neural Networks como modelos sustitutos del análisis estructural para reducir el número de evaluaciones FEM.	El uso de GNN reduce en al menos 60 % el número de evaluaciones FEM, manteniendo un error relativo inferior al 5 % en variables estructurales críticas.	Modelo GNN entrenado.	■ Número de análisis FEM ejecutados ■ Error relativo medio (%) ■ Coeficiente R^2 del modelo
PE4	OE4	HE4	Enfoque de diseño	Indicadores
¿En qué medida la metodología propuesta mejora la eficiencia estructural y computacional frente al enfoque tradicional?	Comparar el desempeño de la metodología propuesta con el enfoque tradicional de diseño de puentes reticulados.	La metodología PSO + GNN reduce el peso estructural en al menos 20 % y el tiempo total de diseño de meses a semanas frente al método tradicional.	Enfoque de diseño (tradicional vs propuesto).	■ Comparación de pesos estructurales ■ Tiempo total de diseño ■ Número total de evaluaciones FEM

1.6. Alcances y delimitaciones

1.6.1. Alcances de la Investigación

La presente investigación se enfoca en el desarrollo y validación de una metodología computacional integrada para la optimización topológica de puentes reticulados metálicos, orientada a mejorar la eficiencia estructural y computacional del proceso de diseño. En este contexto, los principales alcances del estudio son los siguientes:

- La investigación aborda la optimización topológica de la superestructura de puentes reticulados metálicos, considerando la presencia o ausencia de elementos estructurales como variables de diseño discretas.
- Se desarrolla un modelo paramétrico de puentes reticulados mediante el uso de Rhino–Grasshopper, que permite generar de forma automática múltiples configuraciones topológicas y geométricas a partir de un conjunto definido de parámetros estructurales.
- Las configuraciones generadas son evaluadas mediante análisis estructural por el método de los elementos finitos (FEM), garantizando la verificación de los estados límite de resistencia y servicio conforme a los criterios establecidos por la normativa de diseño estructural vigente.
- Se implementa un algoritmo de optimización bioinspirada, basado en Particle Swarm Optimization (PSO), para la exploración eficiente del espacio de configuraciones topológicas posibles.
- Se implementa un algoritmo de optimización bioinspirada, basado en Particle Swarm Optimization (PSO), para la exploración eficiente del espacio de configuraciones topológicas posibles.
- La metodología propuesta se aplica a casos de estudio representativos de puentes reticulados metálicos con luces comprendidas entre 55 m y 100 m, permitiendo evaluar su desempeño en un rango de aplicaciones típicas del contexto nacional.
- Los resultados obtenidos se analizan y comparan con el enfoque tradicional de diseño, evaluando mejoras en términos de peso estructural, tiempo computacional y número de evaluaciones FEM.

1.6.2. Delimitaciones de la Investigación

Con el fin de acotar el alcance del estudio y garantizar su viabilidad dentro del marco de una tesis de maestría, se establecen las siguientes delimitaciones:

- La investigación se limita a puentes reticulados metálicos, no considerando otras tipologías estructurales como puentes de arco, atirantados, colgantes o de concreto armado o postensado.
- El análisis estructural se realiza bajo el supuesto de comportamiento elástico lineal, sin considerar efectos no lineales de material, geometría o interacción suelo-estructura.
- No se incluye el análisis detallado de fenómenos de fatiga, fractura o comportamiento sísmico no lineal, los cuales quedan fuera del alcance del presente estudio.
- La optimización se enfoca en la superestructura del puente, excluyendo el diseño y optimización de subestructuras, apoyos, cimentaciones y elementos accesorios.
- El estudio no aborda aspectos constructivos detallados, tales como secuencias de montaje, costos de fabricación, logística de transporte o procedimientos de lanzamiento, más allá de su impacto indirecto en el peso estructural.
- La validación de los modelos de aprendizaje automático se realiza a partir de datos generados numéricamente mediante análisis FEM, no considerando datos experimentales de laboratorio o mediciones en campo.

Capítulo 2

MARCO TEÓRICO Y ESTADO DEL ARTE

2.1. Puentes reticulados

Los puentes reticulados constituyen una de las tipologías estructurales más estudiadas y empleadas en la ingeniería de puentes, debido a su elevada eficiencia estructural y a la claridad con la que transmiten las cargas hacia los apoyos. Desde el punto de vista mecánico, estas estructuras están conformadas por un conjunto de elementos lineales interconectados en nodos, dispuestos de tal manera que los esfuerzos internos se desarrollan predominantemente en forma de tracción y compresión axial, minimizando la presencia de momentos flectores en las barras. [1].

Esta característica axial dominante convierte a los puentes reticulados en sistemas altamente eficientes desde el punto de vista del uso del material, especialmente cuando se comparan con tipologías de viga o losa para luces medias y grandes. De acuerdo con Chen y Duan (2014) [2], para rangos de luz comprendidos entre 50 m y 100 m, los puentes reticulados metálicos pueden alcanzar reducciones de peso del orden del 20 % al 40 % respecto a soluciones equivalentes basadas en vigas de alma llena, siempre que la topología estructural esté adecuadamente definida.



Figura 2.1: Puente Reticulado el Salao $L=60.0\text{m}$ Fuente: Elaboración Propia.

2.1.1. Evolución histórica y fundamentos estructurales

Históricamente, los puentes reticulados comenzaron a desarrollarse de manera sistemática a partir de la primera mitad del siglo XIX, en un contexto marcado por la Revolución Industrial y la creciente demanda de infraestructuras de transporte capaces de cubrir mayores luces con materiales más eficientes. El uso extensivo del hierro forjado y, posteriormente, del acero estructural permitió superar las limitaciones geométricas y resistentes de los puentes de mampostería y madera, impulsando la adopción de sistemas estructurales basados en barras articuladas dispuestas en configuraciones trianguladas [3]. Los primeros puentes reticulados surgieron como respuesta directa a las necesidades del transporte ferroviario, donde las cargas concentradas, la repetitividad estructural y la necesidad de prefabricación exigían soluciones livianas, resistentes y fácilmente montables. En esta etapa inicial, el diseño de puentes reticulados se apoyaba predominantemente en criterios empíricos y constructivos, derivados de la experiencia acumulada por ingenieros y constructores, más que en una formulación teórica rigurosa. Las configuraciones estructurales eran el resultado de ensayo y error, con un conocimiento limitado del flujo interno de fuerzas y de la interacción entre los distintos elementos del sistema estructural.

Con el avance de la mecánica estructural y la consolidación de principios fundamentales como el equilibrio estático, la compatibilidad de deformaciones y las leyes constitutivas de los materiales, el diseño de puentes reticulados comenzó a evolucionar hacia disposiciones geométricas más racionales y eficientes. La introducción de métodos analíticos para el cálculo de esfuerzos en estructuras articuladas permitió comprender que la triangulación constituía una forma óptima de garantizar la estabilidad geométrica y la transmisión eficiente de cargas mediante esfuerzos axiales de tracción y compresión. Esta comprensión marcó un punto de inflexión en la evolución del diseño estructural, desplazando progresivamente los enfoques puramente empíricos hacia métodos fundamentados en la teoría de estructuras.

Durante la segunda mitad del siglo XIX y comienzos del siglo XX, se desarrollaron y estandarizaron diversas tipologías de puentes reticulados, tales como los sistemas Warren, Pratt y Howe, cada uno de ellos optimizado para condiciones particulares de carga, material y construcción. Estas tipologías no solo representaban soluciones estructurales, sino también una formalización del conocimiento acumulado sobre el comportamiento de sistemas triangulados. La repetición de patrones geométricos permitió la industrialización de la construcción de puentes, reduciendo costos y tiempos de ejecución, y sentó las bases para la prefabricación modular que caracteriza a muchas infraestructuras modernas.

Desde un punto de vista teórico, el comportamiento de un puente reticulado ideal se fundamenta en el supuesto de nudos perfectamente articulados y cargas aplicadas exclusivamente en los nodos, hipótesis que permiten modelar la estructura como un sistema compuesto por elementos sometidos únicamente a esfuerzos axiales. Bajo estas condiciones, el análisis estructural puede realizarse considerando que los elementos no resisten momentos flectores ni esfuerzos cortantes significativos, lo que simplifica considerablemente la formulación matemática del problema y permite obtener soluciones cerradas o semianalíticas en sistemas isostáticos.

Esta idealización constituye uno de los pilares fundamentales de la teoría de estructuras reticuladas y ha sido ampliamente adoptada tanto en la enseñanza de la ingeniería estructural como en el diseño preliminar de puentes reticulados. Al reducir el comportamiento estructural a un sistema de barras axiales, se facilita la identificación de trayectorias de carga, la evaluación de la eficiencia estructural y la comprensión del rol que desempeña cada elemento dentro del sistema global [8].

No obstante, es importante reconocer que esta representación ideal difiere de la realidad constructiva. En la práctica, las uniones entre elementos presentan una rigidez finita, las cargas suelen aplicarse de manera distribuida a lo largo del tablero, y existen efectos secundarios asociados a la excentricidad de conexiones, imperfecciones geométricas y comportamiento no lineal de los materiales. A pesar de ello, la idealización de nudos articulados y cargas nodales continúa siendo una herramienta válida y ampliamente utilizada, especialmente en etapas preliminares de diseño y en procesos de optimización estructural, donde el objetivo principal es identificar configuraciones globalmente eficientes más que capturar con precisión todos los efectos locales.

La persistencia de este modelo idealizado se explica, en gran medida, por su capacidad para capturar el comportamiento dominante de los puentes reticulados: la transmisión de cargas mediante esfuerzos axiales. Estudios teóricos y experimentales han demostrado que, en estructuras adecuadamente trianguladas, los momentos secundarios inducidos por la rigidez de las uniones suelen ser significativamente menores en

comparación con los esfuerzos axiales, especialmente en puentes de luces medias y grandes. Por esta razón, el modelo de barras articuladas continúa siendo una aproximación razonable para la evaluación global del comportamiento estructural.

Desde la perspectiva de la ingeniería estructural moderna, los puentes reticulados pueden clasificarse como sistemas isostáticos o hiperestáticos, dependiendo de la relación entre el número de incógnitas internas y las ecuaciones de equilibrio disponibles. Los sistemas isostáticos presentan la ventaja de una distribución de esfuerzos independiente de las propiedades de rigidez de los elementos, lo que facilita su análisis y reduce la sensibilidad a asentamientos diferenciales o variaciones térmicas. Por otro lado, los sistemas hiperestáticos ofrecen una mayor redundancia estructural y capacidad de redistribución de esfuerzos, a costa de una mayor complejidad analítica.

La elección entre una configuración isostática o hiperestática responde tanto a criterios estructurales como constructivos y económicos. Históricamente, muchos puentes reticulados tempranos fueron diseñados como sistemas isostáticos, aprovechando la simplicidad de cálculo y la confiabilidad del comportamiento estructural. Sin embargo, con el desarrollo de métodos de análisis más avanzados y el aumento de la capacidad computacional, los sistemas hiperestáticos se han vuelto cada vez más comunes, permitiendo una mejor optimización del material y una mayor robustez frente a acciones excepcionales.

En este contexto, el desarrollo de métodos numéricos, particularmente el método de los elementos finitos (FEM), ha transformado radicalmente la forma en que se analizan y diseñan los puentes reticulados. El FEM permite modelar con mayor fidelidad la rigidez de las uniones, la interacción entre el tablero y la retícula, y la distribución real de cargas, superando las limitaciones de los modelos puramente idealizados. Sin embargo, incluso en estos modelos avanzados, la comprensión conceptual derivada del modelo de barras axiales sigue siendo fundamental para interpretar los resultados y validar el comportamiento estructural global.

Desde el punto de vista de la optimización estructural, la idealización de puentes reticulados como sistemas de barras axiales presenta ventajas significativas. Al reducir el problema a un conjunto de elementos discretos con comportamiento predominantemente axial, se facilita la formulación del diseño como un problema de optimización topológica discreta, en el cual la presencia o ausencia de cada elemento puede representarse mediante variables binarias. Esta característica resulta especialmente relevante en el contexto de algoritmos de optimización bioinspirada, los cuales están diseñados para explorar espacios de búsqueda complejos y no convexos.

La evolución histórica de los puentes reticulados, desde soluciones empíricas hasta sistemas altamente racionalizados, refleja una transición gradual hacia enfoques de

diseño cada vez más basados en principios científicos y métodos computacionales. En sus primeras etapas, la optimización del diseño se lograba mediante la experiencia del ingeniero y la observación del desempeño de estructuras existentes. En la actualidad, esta optimización puede abordarse de manera sistemática mediante herramientas computacionales avanzadas, capaces de evaluar miles de configuraciones estructurales en tiempos razonables.

No obstante, a pesar de los avances tecnológicos, el diseño de puentes reticulados continúa enfrentando desafíos significativos relacionados con la complejidad combinatoria del problema de optimización topológica. El número de configuraciones posibles crece exponencialmente con el número de nodos y elementos potenciales, lo que hace inviable la evaluación exhaustiva de todas las alternativas. Esta realidad refuerza la necesidad de integrar enfoques heurísticos y bioinspirados, capaces de identificar soluciones cercanas al óptimo global sin necesidad de explorar exhaustivamente todo el espacio de diseño. Desde una perspectiva académica, el estudio detallado de la evolución histórica y los fundamentos teóricos de los puentes reticulados no solo permite comprender las bases del comportamiento estructural de estas tipologías, sino que también proporciona un marco conceptual sólido para el desarrollo de nuevas metodologías de diseño. La combinación de modelos idealizados, análisis numérico avanzado y técnicas de optimización computacional representa una extensión natural de los principios que han guiado el diseño de puentes reticulados desde sus orígenes.

En síntesis, los puentes reticulados constituyen una tipología estructural cuya evolución histórica está íntimamente ligada al desarrollo de la mecánica estructural y de los métodos de análisis. La idealización de nudos articulados y cargas nodales, si bien simplificada, ha demostrado ser una herramienta poderosa para comprender y diseñar estas estructuras, y continúa siendo relevante en el contexto de la ingeniería estructural moderna. Este marco teórico proporciona la base sobre la cual se desarrollan las metodologías de optimización topológica propuestas en la presente investigación, integrando el conocimiento histórico con las capacidades computacionales contemporáneas para mejorar la eficiencia y sostenibilidad del diseño de puentes reticulados.



Figura 2.2: Puente reticulado metálico histórico de tipología Pratt/Warren (siglo XIX–XX). fuente: HistoricBridges.org.

2.1.2. Tipologías estructurales de puentes reticulados

Las tipologías estructurales de puentes reticulados se definen en función de la disposición geométrica y conectividad de sus elementos cordones, montantes y diagonales, las cuales determinan el flujo interno de fuerzas, el grado de redundancia estructural, la eficiencia en el uso del material y la respuesta global frente a las acciones de servicio y resistencia. Desde una perspectiva conceptual, cada tipología representa una solución estructural específica al problema de transmitir cargas gravitacionales y accidentales hacia los apoyos mediante un sistema de barras predominantemente axiales.

En el diseño de puentes reticulados metálicos, la selección de la tipología no constituye únicamente una decisión geométrica, sino que define el dominio estructural inicial sobre el cual se desarrollan los procesos de análisis, dimensionamiento y, en enfoques avanzados, optimización topológica. Históricamente, esta selección ha estado condicionada por la experiencia del proyectista, la disponibilidad de materiales y los métodos constructivos predominantes, más que por un proceso sistemático de evaluación comparativa entre alternativas.

Reticulado tipo Warren

El sistema Warren se caracteriza por una disposición de diagonales alternadas que conforman una sucesión de triángulos isósceles o equiláteros, generalmente sin montantes verticales. Conceptualmente, esta tipología busca una distribución uniforme de

esfuerzos axiales entre los elementos, evitando concentraciones excesivas en barras específicas.

En el sistema Warren, las diagonales trabajan alternadamente a tracción y compresión, dependiendo de la posición de la carga móvil. Los cordones superiores se encuentran predominantemente en compresión, mientras que los cordones inferiores trabajan a tracción. La ausencia de montantes verticales reduce el número total de elementos, pero puede incrementar las deformaciones verticales si no se controla adecuadamente la relación altura-luz.



Figura 2.3: Brinnington Railway Bridge Autor: Paul Anderson Licencia: Creative Commons Attribution-ShareAlike 2.0 (CC BY-SA 2.0)

Estos puentes están constituidos principalmente por una Concepción numérica típica de

Relación altura-luz: $h = 1/8$ a $1/12$.

Longitud típica de panel: 4m a 7m.

La tipología Warren es la más recurrente en proyectos de puentes metálicos de luz media en el Perú debido a su simplicidad geométrica, facilidad de fabricación y empleo eficiente del acero en trayectorias trianguladas.

A nivel institucional su uso está documentado en expedientes técnicos, tesis universitarias y proyectos ejecutados o supervisados por el Ministerio de Transportes y Comunicaciones (MTC) y sus órganos operativos, en particular Provías Nacional y gobiernos regionales/municipales que recurren a soluciones modulares y de rápida reposición en vías de integración regional, caminos vecinales y puentes de emergencia o rehabilitación. El Manual de Puentes del MTC incluye criterios y ejemplos que hacen explícita la aplicación de armaduras tipo Warren en rangos de luces típicas a escala nacional.



Figura 2.4: Puente Pampa Hermosa. Autor: Artin gustavo vargas barrera. Fuente: <https://www.regionsanmartin.gob.pe/Noticias?url=noticia&i>

Reticulado tipo Pratt

El reticulado tipo Pratt es una tipología estructural de puente reticulado caracterizada por la disposición de montantes verticales y diagonales inclinadas hacia el centro del vano, de tal manera que, bajo cargas gravitacionales predominantes, las diagonales trabajan principalmente a tracción, mientras que los montantes lo hacen a compresión. Conceptualmente, esta configuración responde a un criterio de eficiencia material, ya que el acero presenta un comportamiento mecánico más favorable a tracción que a compresión, especialmente cuando se consideran problemas de pandeo en elementos esbeltos.

Desde el punto de vista del diseño estructural, el sistema Pratt introduce una jerarquización clara de funciones estructurales, asignando roles bien definidos a cada tipo de elemento (cordones, montantes y diagonales). Esta claridad conceptual facilita tanto el análisis estructural como la identificación de elementos críticos, lo que ha contribuido a su amplia adopción histórica y contemporánea.

En un puente reticulado tipo Pratt sometido a cargas verticales, los cordones superiores trabajan predominantemente a compresión, mientras que los cordones inferiores se encuentran sometidos a tracción. Las diagonales inclinadas hacia el centro del vano absorben esfuerzos de tracción, transfiriendo las cargas desde el tablero hacia los cordones, y los montantes verticales trabajan a compresión, contribuyendo al control de deformaciones verticales y a la estabilidad global del sistema.

Esta distribución de esfuerzos resulta especialmente ventajosa en estructuras metálicas, ya que permite dimensionar las diagonales con secciones relativamente esbeltas, reduciendo el peso propio de la superestructura. Asimismo, la presencia de montantes verticales mejora el control de flechas y vibraciones en comparación con sistemas sin montantes, como el Warren puro, lo que resulta relevante en puentes carreteros sometidos a cargas móviles.

Desde el punto de vista de la redundancia estructural, el sistema Pratt puede diseñarse como isostático o hiperestático, dependiendo del número de paneles y de la

continuidad de los elementos. En configuraciones hiperestáticas, el sistema presenta una mayor capacidad de redistribución de esfuerzos frente a acciones excepcionales, lo cual incrementa su robustez estructural.

En la práctica del diseño de puentes reticulados tipo Pratt, se emplean rangos geométricos y estructurales bien establecidos, derivados de la experiencia acumulada y de recomendaciones técnicas internacionales:

Relación altura–luz: $L/h = 1/7$ a $1/10$. Longitud típica de panel: 4m a 6m

A nivel internacional, el reticulado tipo Pratt ha sido ampliamente utilizado desde finales del siglo XIX, particularmente en Estados Unidos, donde se convirtió en una de las tipologías predominantes para puentes ferroviarios y carreteros de luces medias. Su adopción masiva estuvo asociada a la disponibilidad de acero laminado, al desarrollo de métodos de cálculo más precisos y a la necesidad de estructuras capaces de soportar cargas ferroviarias crecientes.

En Europa y Asia, el sistema Pratt también ha sido empleado extensivamente, especialmente en puentes metálicos de carretera y en infraestructuras ferroviarias secundarias. Estudios comparativos internacionales indican que el sistema Pratt presenta un desempeño favorable en términos de relación peso–capacidad, lo que ha motivado su permanencia como una tipología de referencia en manuales de diseño y catálogos de soluciones estructurales [2].

En el contexto peruano, el sistema Pratt es una de las tipologías más utilizadas en puentes reticulados metálicos de carretera, particularmente en rangos de luz comprendidos entre 55 m y 80 m. Su uso se encuentra documentado en expedientes técnicos y tesis universitarias desarrolladas bajo el marco normativo del Manual de Puentes del MTC, el cual reconoce explícitamente esta tipología como una solución válida y recurrente para puentes metálicos de luces medias.

Diversas entidades han promovido o utilizado el sistema Pratt en el Perú, entre las cuales destacan:

- Ministerio de Transportes y Comunicaciones (MTC), a través de sus manuales técnicos y proyectos de infraestructura vial.
- Provías Nacional y Provías Descentralizado, en proyectos de rehabilitación y reposición de puentes metálicos.
- Gobiernos regionales y municipales, especialmente en zonas con limitaciones logísticas donde se requieren soluciones prefabricadas y de montaje relativamente rápido.
- Consultoras y empresas de ingeniería locales, que adoptan el sistema Pratt por su claridad estructural y facilidad de verificación normativa.

En la práctica, el sistema Pratt ha demostrado un buen desempeño en condiciones geográficas y climáticas diversas, incluyendo zonas andinas y amazónicas, donde el control de deformaciones y la facilidad de inspección estructural resultan particularmente relevantes.



Figura 2.5: Puente Cuna Fuente / Sitio: Energiminas




Figura 2.6: Tipologías clásicas de puentes reticulados. Fuente: Troitsky, M. S. (1994). Planning and Design of Bridges (2nd ed.). John Wiley Sons.

2.2. Optimización topológica

La optimización topológica constituye una de las ramas más avanzadas de la optimización estructural y tiene como objetivo determinar la distribución óptima de material dentro de un dominio estructural, de manera que se satisfagan determinados criterios de desempeño, tales como resistencia, rigidez o peso mínimo, bajo un conjunto de restricciones previamente establecidas. A diferencia de la optimización de tamaño o de forma, la optimización topológica permite modificar la conectividad estructural, es decir, la presencia o ausencia de elementos, lo que la convierte en una herramienta particularmente poderosa para el diseño conceptual de estructuras.

Desde una perspectiva general, la optimización topológica busca responder a la pregunta fundamental de la ingeniería estructural: ¿dónde debe colocarse el material

para resistir eficientemente un conjunto dado de cargas? En este sentido, la topología deja de ser una decisión intuitiva o empírica para convertirse en el resultado de un proceso matemático y computacional sistemático.




Figura 2.7: Optimización topológica en estructuras reticuladas para el diseño conceptual. Fuente: Adaptado de Bendsøe y Sigmund (2003).

2.2.1. Evolución y fundamentos conceptuales

El desarrollo de la optimización topológica se remonta a los trabajos pioneros en optimización estructural realizados durante la segunda mitad del siglo XX, impulsados por el avance de la teoría de la elasticidad y el incremento progresivo de la capacidad computacional. Inicialmente, los problemas de optimización estructural se abordaban mediante la optimización de secciones transversales, manteniendo fija la geometría y la conectividad del sistema. Sin embargo, se reconoció tempranamente que muchas de las ineficiencias estructurales estaban asociadas a decisiones topológicas adoptadas en etapas tempranas del diseño.

Con la formalización matemática de la optimización topológica, se estableció un marco que permite tratar la distribución del material como una variable de diseño, sujeta a restricciones de comportamiento estructural. Este enfoque ha sido ampliamente aplicado en el diseño de componentes mecánicos, aeronáuticos y civiles, y ha demostrado su capacidad para generar configuraciones estructurales no triviales, difíciles de concebir mediante métodos tradicionales.

2.2.2. Optimización topológica continua y discreta

Desde el punto de vista metodológico, la optimización topológica puede clasificarse en dos grandes enfoques: optimización topológica continua y optimización topológica discreta. La optimización topológica continua se aplica típicamente a dominios sólidos continuos, donde el material se distribuye dentro de un volumen mediante variables continuas que representan densidades relativas. Este enfoque permite obtener configu-

raciones orgánicas y altamente eficientes, pero requiere procesos de interpretación y postprocesamiento para su materialización constructiva.

Por otro lado, la optimización topológica discreta se orienta a sistemas estructurales compuestos por elementos discretos, como las estructuras reticuladas. En este caso, el dominio estructural se define a partir de un conjunto finito de nodos y elementos potenciales, y la variable de diseño se asocia a la presencia o ausencia de cada elemento estructural, usualmente representada mediante variables binarias. Este enfoque resulta particularmente adecuado para puentes reticulados metálicos, donde la estructura real está compuesta por barras claramente definidas.




Figura 2.8: Comparación conceptual entre optimización topológica continua y optimización topológica discreta en estructuras. Fuente: Adaptado de Bendsøe y Sigmund (2003) y Michell (1904).

La Figura 2.8 ilustra conceptualmente la diferencia entre ambos enfoques, destacando la naturaleza continua del dominio material en un caso y la naturaleza discreta y modular de los sistemas reticulados en el otro.

2.2.2.1 Optimización topológica continua

La optimización topológica continua se aplica a dominios estructurales continuos, generalmente sólidos bidimensionales o tridimensionales, en los cuales el material puede distribuirse de manera variable dentro de un volumen predefinido. En este enfoque, el dominio de diseño se discretiza mediante una malla de elementos finitos, y a cada elemento se le asigna una variable continua de diseño, comúnmente interpretada como una densidad relativa de material.

Bendsøe y Kikuchi (1988) formalizaron este enfoque al introducir el método de optimización topológica basado en la teoría de homogenización, sentando las bases para el desarrollo posterior de técnicas ampliamente difundidas como el método SIMP (Solid Isotropic Material with Penalization). En este marco, la variable de diseño ρ_e asociada a cada elemento finito puede tomar valores continuos en el intervalo:

$$0 \leq \rho_e \leq 1.$$

Donde $\rho_e = 0$ representa la ausencia de material y $\rho_e = 1$ representa material sólido completo. La optimización topológica continua permite generar configuraciones altamente eficientes y no intuitivas, con trayectorias de carga orgánicas que siguen los principales flujos de esfuerzo. Este enfoque ha demostrado ser particularmente efectivo en el diseño de componentes mecánicos, estructuras aeroespaciales y piezas manufacturadas mediante impresión 3D.

Sin embargo, presenta limitaciones importantes cuando se traslada al ámbito de la ingeniería civil y, en particular, al diseño de puentes:

- Las soluciones obtenidas suelen requerir interpretación geométrica y redefinición manual para su construcción.
- Se generan regiones de densidad intermedia (“material gris”) que carecen de significado físico directo.
- La transición desde un sólido continuo optimizado hacia un sistema de barras discretas no es trivial.
- El costo computacional es elevado para dominios de gran escala.

Rozvany (2009) [9] destaca que, si bien la optimización topológica continua es conceptualmente elegante, su aplicación directa a estructuras de ingeniería civil de gran tamaño resulta limitada sin procesos adicionales de simplificación y postprocesamiento.




Figura 2.9: Optimización topológica continua aplicada a un dominio estructural sólido mediante el método de densidades. Fuente: Adaptado de Bendsøe y Sigmund (2003).

2.2.2.2 Optimización topológica discreta

La optimización topológica discreta se define como un enfoque de diseño estructural en el cual el dominio de diseño está compuesto por un conjunto finito de elementos discretos, y la variable de decisión asociada a cada elemento indica su presencia o ausencia dentro de la estructura final. En este marco, la topología estructural se representa mediante variables discretas usualmente binarias, lo que permite modelar de forma directa sistemas estructurales reales compuestos por barras, vigas o cables, como es el caso de las estructuras reticuladas [3].

Desde el punto de vista conceptual, la optimización topológica discreta se encuentra estrechamente vinculada a la teoría de grafos y a la optimización combinatoria. Cada configuración estructural puede interpretarse como un subgrafo del dominio inicial, en el cual se busca identificar el conjunto óptimo de conexiones que garantice el desempeño estructural requerido con el menor consumo de material. Este enfoque resulta especialmente coherente con la realidad constructiva de los puentes reticulados, donde la estructura está compuesta por barras claramente definidas y conectadas en nodos específicos [4].

Una apreciación central de la optimización topológica discreta es que el problema resultante es intrínsecamente no convexo y combinatorio, ya que el número de configuraciones posibles crece exponencialmente con el número de elementos potenciales. Rozvany (2009) [9] señala que esta característica hace inviable la resolución del problema mediante métodos deterministas clásicos, lo que ha motivado el uso extensivo de algoritmos heurísticos y metaheurísticos en este campo.

A diferencia del enfoque continuo, la optimización topológica discreta no requiere procesos de interpretación geométrica complejos, ya que las soluciones obtenidas corresponden directamente a configuraciones estructurales fabricables. Esta ventaja ha llevado a diversos autores a considerar este enfoque como el más adecuado para aplicaciones en ingeniería civil, particularmente en estructuras metálicas reticuladas, donde la eliminación o activación de elementos puede evaluarse de manera directa en función de su contribución estructural [3] [4].

Desde una perspectiva crítica, múltiples autores coinciden en que la elección entre optimización topológica continua y discreta debe realizarse en función del tipo de estructura, la escala del problema y el objetivo del diseño. Bendsøe y Sigmund [6] destacan que la optimización continua es conceptualmente poderosa para explorar trayectorias óptimas de carga, mientras que la optimización discreta ofrece una correspondencia más directa con sistemas estructurales reales. En el ámbito específico de los puentes reticulados, la literatura técnica reconoce que la optimización topológica discreta presenta ventajas sustanciales, al permitir una formulación del problema alineada

con la naturaleza axial y modular de estas estructuras. Kaveh [4] resalta que, en este tipo de sistemas, la optimización discreta permite identificar configuraciones altamente eficientes mediante la eliminación sistemática de elementos redundantes, logrando reducciones significativas de peso sin comprometer el cumplimiento normativo.

En consecuencia, la optimización topológica discreta ha sido adoptada como el enfoque predominante en investigaciones orientadas al diseño óptimo de armaduras y puentes reticulados, especialmente cuando se integra con algoritmos bioinspirados capaces de explorar de manera eficiente espacios de búsqueda complejos. Esta apreciación fundamenta la selección metodológica adoptada en la presente investigación, en la cual la optimización topológica discreta se combina con técnicas avanzadas de optimización y aprendizaje automático para superar sus limitaciones computacionales.




Figura 2.10: Optimización topológica discreta aplicada a una estructura reticulada mediante el método de la estructura base (ground structure). Fuente: Adaptado de Michell (1904) y Rozvany (2009).

2.3. Optimización bioinspirada

La optimización bioinspirada constituye una familia de métodos de optimización heurística y metaheurística cuyo principio fundamental se basa en la imitación de procesos naturales, tales como la evolución biológica, el comportamiento colectivo de organismos sociales y los mecanismos de adaptación observados en sistemas físicos y biológicos. Estos métodos han sido ampliamente adoptados para la resolución de problemas de optimización complejos, caracterizados por espacios de búsqueda no convexos, alta dimensionalidad, discontinuidades y múltiples óptimos locales, condiciones que son típicas en problemas de optimización estructural avanzada [4].

Desde una perspectiva conceptual, los algoritmos bioinspirados no buscan garanti-

zar la obtención del óptimo global exacto, sino identificar soluciones cercanas al óptimo global mediante estrategias de exploración y explotación del espacio de diseño, logrando un balance eficiente entre precisión de la solución y costo computacional. Esta característica los convierte en herramientas especialmente adecuadas para problemas donde los métodos deterministas clásicos resultan ineficientes o impracticables.

2.3.1. Fundamentos conceptuales de la optimización bioinspirada

El fundamento teórico de la optimización bioinspirada se apoya en la observación de que muchos sistemas naturales exhiben comportamientos colectivos altamente eficientes sin la existencia de un control centralizado. En estos sistemas, la interacción local entre individuos conduce a patrones globales emergentes que permiten resolver problemas complejos, como la búsqueda de alimento, la adaptación al entorno o la supervivencia de la especie.

En el ámbito de la optimización, estos principios se traducen en algoritmos que utilizan poblaciones de soluciones candidatas, las cuales evolucionan iterativamente a partir de reglas simples inspiradas en la naturaleza. Cada individuo de la población representa una solución potencial del problema, y la calidad de dicha solución se evalúa mediante una función objetivo, que guía el proceso evolutivo o adaptativo (Talbi, 2009).

Una característica distintiva de estos métodos es su independencia de derivadas, lo que les permite operar eficazmente en problemas donde la función objetivo es discontinua, ruidosa o definida implícitamente a través de modelos numéricos complejos, como ocurre en la optimización topológica de estructuras mediante análisis por elementos finitos.

2.3.2. Clasificación de algoritmos bioinspirados

Los algoritmos bioinspirados pueden clasificarse, de manera general, en función del fenómeno natural que los inspira. Entre las categorías más relevantes se encuentran las siguientes:

a) Algoritmos evolutivos

Los algoritmos evolutivos se inspiran en los principios de la selección natural y la genética, donde una población de individuos evoluciona mediante operadores de selección, cruzamiento y mutación. El Algoritmo Genético (GA) es el representante más conocido de esta categoría y ha sido ampliamente utilizado en problemas de optimización estructural discreta.

Desde el punto de vista teórico, los algoritmos evolutivos permiten una exploración




Figura 2.11: Integración conceptual entre algoritmos evolutivos y neuronas artificiales para la optimización de parámetros en modelos de inteligencia artificial. Fuente: Adaptado de Goldberg (1989) y Yao (1999).

amplia del espacio de búsqueda, pero pueden presentar una convergencia relativamente lenta y una alta sensibilidad a la calibración de sus parámetros (Goldberg, 1989).

b) Algoritmos basados en inteligencia de enjambres

Los algoritmos de inteligencia de enjambres se inspiran en el comportamiento colectivo de organismos sociales, como bandadas de aves, cardúmenes de peces o colonias de insectos. En estos algoritmos, la cooperación indirecta entre individuos permite la emergencia de soluciones eficientes.

Entre los algoritmos más representativos de esta categoría se encuentran el Particle Swarm Optimization (PSO) y la Optimización por Colonia de Hormigas (ACO). Estos métodos destacan por su simplicidad conceptual, bajo número de parámetros y buena capacidad de convergencia en problemas continuos y discretos (Kennedy & Eberhart, 1995).




Figura 2.12: Flujo conceptual de los algoritmos basados en inteligencia de enjambres aplicados a problemas de optimización. Fuente: Adaptado de Kennedy y Eberhart (1995).

c) Algoritmos inspirados en procesos físicos y químicos

Esta categoría incluye algoritmos basados en fenómenos como el recocido térmico, la cristalización o la dinámica de sistemas físicos. El Simulated Annealing (SA) es uno de los ejemplos más conocidos, inspirado en el proceso de enfriamiento controlado de materiales para alcanzar estados de mínima energía.

2.3.3. Optimización bioinspirada en ingeniería estructural

En ingeniería estructural, los algoritmos bioinspirados han demostrado ser especialmente eficaces en problemas donde el número de variables de diseño es elevado y las relaciones entre variables y respuesta estructural son altamente no lineales. Ejemplos típicos incluyen la optimización de secciones transversales, la disposición de elementos estructurales y la optimización topológica de armaduras y marcos estructurales.

Diversos estudios han evidenciado que los métodos bioinspirados permiten alcanzar configuraciones estructurales con reducciones significativas de peso en comparación con enfoques tradicionales, manteniendo el cumplimiento de los criterios normativos de resistencia y servicio [3] [4]. Esta capacidad resulta particularmente relevante en estructuras metálicas, donde el costo del material representa una fracción significativa del costo total del proyecto.




Figura 2.13: Aplicación de la optimización bioinspirada en problemas de ingeniería estructural. Fuente: Adaptado de Goldberg (1989) y Kennedy y Eberhart (1995).

2.4. Particle Swarm Optimization (PSO)

El Particle Swarm Optimization (PSO) es un algoritmo de optimización bioinspirado perteneciente a la familia de métodos de inteligencia de enjambres, propuesto originalmente por Kennedy y Eberhart en 1995. Su desarrollo se basa en la observación del comportamiento colectivo de organismos sociales, como bandadas de aves o cardúmenes de peces, los cuales son capaces de localizar regiones óptimas de alimento mediante interacciones simples y descentralizadas entre individuos. A partir de esta analogía, el PSO modela el proceso de búsqueda de soluciones como la evolución de un conjunto de partículas que cooperan entre sí para explorar eficientemente un espacio de diseño complejo (Kennedy & Eberhart, 1995).

Desde un punto de vista conceptual, el PSO se clasifica como un algoritmo estocástico basado en población, en el cual cada partícula representa una solución candidata del problema de optimización. El conjunto de partículas, denominado enjambre, se desplaza iterativamente dentro del espacio de búsqueda guiado por reglas matemáticas simples que combinan la experiencia individual de cada partícula con la experiencia colectiva del grupo. A diferencia de los algoritmos evolutivos clásicos, como los algoritmos genéticos, el PSO no emplea operadores de cruzamiento ni mutación, sino que basa su funcionamiento en un mecanismo de aprendizaje social continuo.

La arquitectura del algoritmo PSO se fundamenta en tres conceptos principales: la posición de la partícula, la velocidad de desplazamiento y la memoria histórica. La posición representa el estado actual de la solución candidata, mientras que la velocidad controla la magnitud y dirección del cambio de dicha solución en el espacio de búsqueda. Cada partícula almacena en su memoria la mejor posición alcanzada durante su trayectoria, conocida como personal best (pbest), y recibe información sobre la mejor posición encontrada por todo el enjambre, denominada global best (gbest). Este in-

tercambio de información constituye el núcleo del proceso de aprendizaje colectivo del algoritmo.

Desde el punto de vista matemático, el comportamiento dinámico del PSO se describe mediante ecuaciones de actualización de la velocidad y de la posición. La velocidad de cada partícula se actualiza como una combinación ponderada de tres componentes: un término de inercia que representa la tendencia a mantener el movimiento previo, un término cognitivo asociado al retorno hacia la mejor experiencia individual, y un término social que atrae a la partícula hacia la mejor solución global. Esta formulación permite equilibrar la exploración global del espacio de diseño con la explotación local de regiones prometedoras, aspecto fundamental para evitar la convergencia prematura hacia óptimos locales.

El parámetro de inercia desempeña un rol clave en la dinámica del PSO, ya que controla la persistencia del movimiento de las partículas. Valores elevados del factor de inercia favorecen la exploración del espacio de búsqueda, mientras que valores reducidos promueven la convergencia hacia soluciones estables. Por su parte, los coeficientes cognitivo y social regulan la influencia relativa de la experiencia individual y colectiva, respectivamente. Estudios posteriores al desarrollo original del algoritmo han demostrado que la estabilidad y convergencia del PSO dependen críticamente del balance adecuado entre estos parámetros, lo que ha dado lugar a diversas estrategias adaptativas y análisis de estabilidad del algoritmo (Clerc & Kennedy, 2002).

Originalmente, el PSO fue concebido para problemas de optimización con variables continuas. No obstante, debido a su simplicidad conceptual y flexibilidad, el algoritmo fue posteriormente extendido para abordar problemas discretos y combinatorios mediante variantes como el Particle Swarm Optimization binario (BPSO). En esta formulación, la posición de la partícula no representa una coordenada continua, sino un estado binario que indica la activación o desactivación de una variable de diseño. La velocidad, en este contexto, se interpreta como una medida de propensión o probabilidad de que la variable adopte el valor uno, lo que permite adaptar el mecanismo de aprendizaje social del PSO a problemas discretos.

Esta capacidad de adaptación ha convertido al PSO en una herramienta especialmente adecuada para la optimización topológica discreta de estructuras reticuladas, donde la presencia o ausencia de elementos estructurales puede representarse mediante variables binarias. En este tipo de problemas, el espacio de búsqueda es altamente combinatorio y no convexo, lo que dificulta la aplicación de métodos deterministas tradicionales. El PSO, al no requerir derivadas ni continuidad de la función objetivo, puede explorar eficazmente este tipo de espacios, identificando configuraciones estructurales eficientes con un número relativamente reducido de evaluaciones.

En el ámbito de la ingeniería estructural, el PSO ha sido aplicado con éxito en problemas de optimización de secciones transversales, diseño óptimo de armaduras, optimización topológica de pórticos y calibración de modelos estructurales. Diversos estudios reportan reducciones significativas de peso estructural, del orden del 15 % al 30 %, cuando se emplea PSO en comparación con enfoques tradicionales de diseño basados en iteraciones manuales, manteniendo el cumplimiento de los criterios normativos de resistencia y servicio (Ghavami, 2008; Kaveh, 2014).

No obstante, el uso del PSO en problemas estructurales de gran escala presenta desafíos importantes, particularmente cuando cada evaluación de la función objetivo implica la ejecución de un análisis estructural mediante el método de los elementos finitos. En estos casos, el costo computacional puede incrementarse de manera significativa, limitando la aplicabilidad del algoritmo en problemas reales. Esta limitación ha motivado el desarrollo de enfoques híbridos, en los cuales el PSO se combina con modelos sustitutos basados en aprendizaje automático para aproximar la respuesta estructural y reducir el número de análisis requeridos.

En el contexto de la presente investigación, el Particle Swarm Optimization se adopta como el algoritmo central de optimización bioinspirada para la exploración del espacio de configuraciones topológicas de puentes reticulados metálicos. Su formulación binaria permite representar de manera directa la activación o eliminación de elementos estructurales, mientras que su integración con modelos de aprendizaje automático, como las Graph Neural Networks, permite mitigar el elevado costo computacional asociado a la evaluación estructural repetitiva. De este modo, el PSO se constituye como una herramienta clave para modernizar el proceso de diseño estructural, permitiendo abordar de manera sistemática y eficiente problemas de optimización topológica en estructuras reales de ingeniería civil.




Figura 2.14: Esquema híbrido de optimización basado en Particle Swarm Optimization (PSO) y mapas autoorganizados (SOM) en el espacio cartesiano. Fuente: Zhang et al. (2024).

El comportamiento dinámico del algoritmo Particle Swarm Optimization se describe mediante un sistema de ecuaciones que gobiernan la evolución de la velocidad y la posición de cada partícula en el espacio de búsqueda. Estas ecuaciones modelan el proceso de aprendizaje individual y social que caracteriza al algoritmo.

2.5. Aprendizaje automático en ingeniería estructural

El aprendizaje automático constituye una rama de la inteligencia artificial orientada al desarrollo de algoritmos capaces de identificar patrones y relaciones en datos, con el fin de realizar predicciones, clasificaciones o decisiones sin necesidad de una programación explícita basada en reglas deterministas. En ingeniería estructural, el aprendizaje automático ha emergido como una herramienta complementaria a los métodos tradicionales de análisis, permitiendo abordar problemas caracterizados por alta complejidad, no linealidad y elevado costo computacional, como la simulación de comportamiento estructural, la identificación de daños y la optimización del diseño (Goodfellow et al., 2016).

Desde un punto de vista formal, el aprendizaje automático se basa en la construcción de modelos matemáticos parametrizados que se ajustan a un conjunto de datos mediante procesos de entrenamiento, con el objetivo de minimizar una función de pérdida que cuantifica el error entre las predicciones del modelo y los valores reales observados. Este

enfoque permite capturar relaciones implícitas entre variables de entrada y salida que resultan difíciles de formular de manera analítica, especialmente cuando intervienen múltiples parámetros geométricos, materiales y de carga.

En el contexto de la ingeniería estructural, el aprendizaje automático se utiliza principalmente como un medio para aproximar funciones complejas asociadas al comportamiento de las estructuras, tales como la relación entre cargas aplicadas y desplazamientos resultantes, la distribución de esfuerzos internos o la probabilidad de falla bajo condiciones específicas. Estos modelos se conocen comúnmente como modelos sustitutos o *surrogate models*, y su principal ventaja radica en su capacidad para reducir significativamente el costo computacional asociado a la evaluación repetitiva de modelos numéricos de alta fidelidad, como los basados en el método de los elementos finitos.

Las técnicas de aprendizaje automático pueden clasificarse, de manera general, en aprendizaje supervisado, no supervisado y por refuerzo. En aplicaciones estructurales, el aprendizaje supervisado es el enfoque predominante, ya que se dispone habitualmente de conjuntos de datos etiquetados generados mediante simulaciones numéricas o mediciones experimentales. En este enfoque, el modelo aprende una función que mapea las variables de entrada, por ejemplo, geometría estructural, propiedades de material y condiciones de carga hacia variables de salida de interés, como desplazamientos máximos, tensiones críticas o factores de seguridad.

Entre los modelos de aprendizaje automático más utilizados en ingeniería estructural se encuentran las redes neuronales artificiales, las máquinas de soporte vectorial y los métodos basados en árboles de decisión. Las redes neuronales, en particular, han demostrado una notable capacidad para aproximar funciones no lineales de alta dimensionalidad, lo que las hace especialmente adecuadas para modelar la respuesta estructural bajo múltiples escenarios de carga y configuración geométrica. Estudios recientes muestran que redes neuronales entrenadas adecuadamente pueden predecir desplazamientos y esfuerzos con errores relativos inferiores al 5 %, en comparación con análisis FEM completos, reduciendo el tiempo de cómputo en varios órdenes de magnitud (Adeli & Panakkat, 2009; Sun et al., 2020).

Una de las aplicaciones más relevantes del aprendizaje automático en ingeniería estructural es la evaluación rápida del desempeño estructural. En lugar de ejecutar un análisis FEM completo para cada nueva configuración estructural, el modelo entrenado puede proporcionar una estimación inmediata del comportamiento esperado, lo que resulta particularmente valioso en contextos de optimización, donde se requiere evaluar miles de alternativas. Esta capacidad habilita la integración efectiva del aprendizaje automático con algoritmos de optimización bioinspirada, permitiendo reducir el costo

computacional global del proceso.

Asimismo, el aprendizaje automático ha sido ampliamente aplicado en la identificación de daños estructurales, donde se utilizan datos de sensores para detectar cambios en las propiedades dinámicas de la estructura que puedan indicar deterioro o daño. En este contexto, los modelos aprenden patrones asociados a estados sanos y dañados, facilitando la detección temprana de problemas y la planificación de intervenciones de mantenimiento (Farrar & Worden, 2012).

No obstante, el uso del aprendizaje automático en ingeniería estructural presenta limitaciones importantes que deben ser consideradas críticamente. En primer lugar, la calidad del modelo depende fuertemente de la calidad y representatividad del conjunto de datos de entrenamiento. Si los datos no cubren adecuadamente el espacio de configuraciones posibles, el modelo puede presentar errores significativos al extrapolar fuera del rango de entrenamiento. En segundo lugar, muchos modelos de aprendizaje automático carecen de interpretabilidad física, lo que dificulta la validación ingenieril de sus predicciones y limita su aceptación en contextos normativos y regulatorios.

En respuesta a estas limitaciones, se han desarrollado enfoques híbridos que combinen modelos basados en datos con principios físicos conocidos, dando lugar a lo que se denomina aprendizaje automático informado por la física (physics-informed machine learning). Estos enfoques buscan incorporar restricciones derivadas de las leyes físicas en el proceso de entrenamiento, mejorando la generalización del modelo y asegurando la coherencia de sus predicciones con el comportamiento estructural esperado.

En el marco de la presente investigación, el aprendizaje automático se emplea como un componente clave para aproximar la respuesta estructural de puentes reticulados metálicos durante el proceso de optimización topológica. La utilización de modelos sustitutos basados en aprendizaje automático permite reducir el número de análisis FEM requeridos, haciendo viable la aplicación de algoritmos bioinspirados en problemas de escala real. De este modo, el aprendizaje automático no sustituye al análisis estructural tradicional, sino que lo complementa, actuando como un acelerador computacional dentro de un marco metodológico integrado.

2.6. Graph Neural Networks (GNN)

Las Graph Neural Networks (GNN) constituyen una clase de modelos de aprendizaje profundo diseñados específicamente para procesar datos estructurados en forma de grafos, donde las relaciones entre entidades son tan relevantes como las propiedades individuales de cada entidad. A diferencia de las redes neuronales tradicionales, que operan sobre datos organizados en estructuras regulares como vectores o matrices, las

$$h_v^{(k+1)} = \sigma(W^{(k)} \sum_{u \in N(v)} h_u^k + b^k)$$

GNN permiten modelar sistemas complejos definidos por nodos y aristas, preservando explícitamente la topología del sistema analizado.

Desde el punto de vista formal, un grafo se define como $G=(V,E)$, donde V representa el conjunto de nodos y E el conjunto de aristas que conectan dichos nodos.

En ingeniería estructural, esta representación resulta especialmente natural, ya que una estructura reticulada puede modelarse directamente como un grafo en el que los nodos corresponden a uniones estructurales y las aristas representan barras sometidas a esfuerzos axiales. Esta correspondencia directa entre el modelo estructural y la representación matemática utilizada por las GNN constituye una de las principales razones para su adopción en aplicaciones estructurales.

El principio fundamental de las GNN se basa en el mecanismo de message passing, mediante el cual cada nodo actualiza su estado interno a partir de la información proveniente de sus vecinos inmediatos. Este proceso se repite iterativamente a lo largo de múltiples capas de la red, permitiendo que la información local se propague progresivamente por todo el grafo. Como resultado, el estado final de cada nodo incorpora información no solo de sus vecinos directos, sino también de regiones más distantes de la estructura, capturando patrones globales emergentes.

Desde el punto de vista matemático, una capa típica de una GNN puede describirse como:

Donde h_v^k es el vector de características del nodo v en la capa k , $N(v)$ es el conjunto de vecinos del nodo y W^k es la matriz de pesos entrenables.

Una de las principales fortalezas de las GNN es su capacidad para generalizar sobre grafos de distinto tamaño y topología, lo que resulta particularmente relevante en el análisis de estructuras donde la geometría y la conectividad pueden variar significativamente entre diferentes configuraciones. En el contexto de la optimización topológica, esta capacidad permite entrenar un modelo sobre un conjunto de estructuras reticuladas y luego aplicar el modelo entrenado para predecir el comportamiento de nuevas topologías no vistas durante el entrenamiento.

En aplicaciones de ingeniería estructural, las GNN han sido utilizadas para aproximar respuestas estructurales como desplazamientos máximos, distribuciones de esfuerzos y factores de seguridad, actuando como modelos sustitutos del análisis FEM. Estudios recientes reportan que modelos basados en GNN pueden predecir respuestas

estructurales con errores relativos inferiores al 5 %, reduciendo el tiempo de evaluación en varios órdenes de magnitud en comparación con simulaciones numéricas completas (Chen et al., 2021; Sanchez-Gonzalez et al., 2020).

No obstante, el uso de GNN en ingeniería estructural también presenta desafíos. En primer lugar, el entrenamiento de estos modelos requiere conjuntos de datos suficientemente grandes y representativos, lo que implica un esfuerzo computacional significativo para generar los datos mediante simulaciones FEM. En segundo lugar, la interpretabilidad de los modelos sigue siendo limitada, lo que dificulta la validación física de las predicciones. Finalmente, la extrapolación fuera del rango de entrenamiento puede conducir a errores no controlados, por lo que es indispensable complementar las predicciones del modelo con validaciones estructurales convencionales en las etapas finales del diseño.

En el marco de la presente investigación, las Graph Neural Networks se emplean como modelos sustitutos para aproximar el comportamiento estructural de puentes reticulados metálicos durante el proceso de optimización topológica. Su capacidad para representar explícitamente la topología estructural y capturar interacciones entre elementos las convierte en una herramienta especialmente adecuada para este tipo de sistemas. Integradas con algoritmos de optimización bioinspirada como el PSO, las GNN permiten reducir significativamente el costo computacional del proceso de búsqueda, manteniendo al mismo tiempo un nivel aceptable de precisión en la evaluación estructural.

2.7. Método de Elementos Finitos

El Método de los Elementos Finitos constituye una de las herramientas numéricas más ampliamente utilizadas para el análisis estructural de sistemas complejos en ingeniería civil y mecánica. Su principio fundamental consiste en discretizar un dominio continuo en un conjunto finito de subdominios, denominados elementos, sobre los cuales se formulan aproximaciones locales del comportamiento físico. Estas aproximaciones se ensamblan posteriormente para obtener una representación global del sistema, permitiendo resolver problemas de equilibrio, deformación y transmisión de esfuerzos que no admiten soluciones analíticas cerradas (Zienkiewicz et al., 2014).

Desde el punto de vista matemático, el FEM se basa en la formulación variacional de los problemas de mecánica del continuo, particularmente en el principio de los trabajos virtuales y en el método de Galerkin. A partir de estas formulaciones, las ecuaciones diferenciales que gobiernan el comportamiento estructural se transforman en un sistema algebraico de ecuaciones lineales o no lineales que puede resolverse mediante

$$K_e = \frac{EA}{L} \begin{bmatrix} c^2 & cs & -cs & cs & s^2 & -cs & -c^2 & -cs & c^2 \end{bmatrix}$$

métodos numéricos estándar. Esta transformación permite tratar geometrías complejas, condiciones de borde arbitrarias y materiales con comportamiento no lineal de manera sistemática y consistente.

En el contexto del análisis estructural, el FEM permite resolver el problema fundamental de equilibrio expresado en forma matricial como:

$$Ku = f$$

donde K es la matriz global de rigidez del sistema, u es el vector de desplazamientos nodales desconocidos y F es el vector de fuerzas externas aplicadas. La matriz de rigidez global se obtiene mediante el ensamblaje de las matrices de rigidez locales de cada elemento, las cuales dependen de las propiedades geométricas, materiales y del tipo de elemento considerado.

Para el caso específico de estructuras reticuladas, cada elemento se modela típicamente como una barra axial con comportamiento lineal elástico, cuya matriz de rigidez local en coordenadas globales puede expresarse como:

donde E es el módulo de elasticidad del material, A es el área de la sección transversal, L es la longitud del elemento y C y S son los cosenos directores del elemento respecto a los ejes globales. Esta formulación permite representar de manera precisa la contribución axial de cada barra al comportamiento global de la estructura.

Una vez resuelto el sistema de ecuaciones, se obtienen los desplazamientos nodales, a partir de los cuales pueden calcularse las deformaciones y esfuerzos internos en cada elemento. Estos valores se comparan posteriormente con los límites admisibles establecidos por las normas de diseño estructural, permitiendo verificar el cumplimiento de los estados límite de resistencia y servicio.

El FEM presenta ventajas significativas en el análisis de estructuras complejas, ya que permite modelar geometrías arbitrarias, incorporar condiciones de frontera realistas y considerar efectos como no linealidad material, grandes desplazamientos o contacto entre elementos. Sin embargo, estas capacidades conllevan un incremento del costo computacional, particularmente cuando se analizan múltiples configuraciones estructurales dentro de procesos de optimización.

En problemas de optimización topológica, como los abordados en la presente investigación, el FEM se emplea como el método de referencia para evaluar el desempeño estructural de cada configuración generada por el algoritmo de optimización. No obstante, el elevado costo computacional asociado a la ejecución repetitiva de análisis FEM motiva la integración de modelos sustitutos basados en aprendizaje automático, los cuales permiten aproximar la respuesta estructural durante la fase exploratoria del

proceso de optimización.

En consecuencia, el FEM no es reemplazado por los modelos de aprendizaje automático, sino que se mantiene como el estándar de validación final de las soluciones obtenidas, garantizando que las configuraciones optimizadas cumplan con los requisitos normativos y de seguridad estructural. De este modo, el FEM se posiciona como un componente fundamental dentro del marco metodológico híbrido propuesto en esta investigación.

2.7.1. Elemento finito tipo Frame

Un elemento finito tipo frame es un elemento unidimensional utilizado para modelar miembros estructurales esbeltos capaces de resistir simultáneamente fuerzas axiales, momentos flectores, fuerzas cortantes y torsión. Este tipo de elemento conecta dos nodos del modelo y presenta, en general, seis grados de libertad por nodo en un análisis tridimensional, correspondientes a tres desplazamientos traslacionales y tres rotaciones. Su formulación se basa en la teoría de vigas de Euler–Bernoulli o de Timoshenko, dependiendo del nivel de refinamiento requerido, permitiendo representar el comportamiento combinado de tracción–compresión, flexión y cortante dentro de un mismo marco matemático (Bathe, 1996).

Desde el punto de vista estructural, los elementos frame se utilizan para modelar vigas, columnas, cordones, montantes y diagonales cuando se desea considerar efectos de flexión, rigidez rotacional de las uniones o interacción axial–flexión. En el análisis de puentes reticulados metálicos, su uso resulta particularmente relevante cuando las uniones no pueden idealizarse como articuladas o cuando se requiere evaluar efectos de segundo orden y rigidez fuera del plano. Su capacidad para representar múltiples mecanismos resistentes los convierte en una herramienta versátil para el análisis de estructuras tridimensionales complejas.




Figura 2.15: Característica de elemento tipo frame Fuente: Adaptado de la formulación clásica del método de elementos finitos para estructuras tipo frame (FEM).

2.7.2. Elemento finito tipo shell

Un elemento finito tipo shell es un elemento bidimensional utilizado para modelar estructuras laminares delgadas capaces de resistir simultáneamente esfuerzos de membrana en su plano y momentos de flexión fuera de él. Este tipo de elemento representa superficies estructurales como losas, placas, chapas metálicas, tableros de puentes y almas de vigas tipo cajón, y se caracteriza por integrar en una misma formulación el comportamiento de placa y de membrana (Zienkiewicz et al., 2014).

Desde el punto de vista mecánico, los elementos shell permiten capturar estados complejos de tensión bidimensional, incluyendo esfuerzos normales, cortantes y momentos flectores distribuidos sobre una superficie. Esto los hace particularmente adecuados para representar componentes estructurales sometidos a cargas distribuidas, efectos locales de concentración de esfuerzos y fenómenos de flexión y cortante transversal. En el análisis de puentes, los elementos shell se emplean típicamente para modelar el tablero, diafragmas, chapas de rigidización y otros componentes laminares cuya respuesta no puede representarse adecuadamente mediante elementos unidimensionales.




Figura 2.16: Elemento finito de tipo shell con nodos y grados de libertad típicos para el análisis de estructuras delgadas en el método de los elementos finitos. Fuente: Adaptado de Jung y Han (2013)

2.8. Modelo Paramétrico Computacional

El modelo paramétrico computacional constituye una herramienta fundamental para la generación sistemática de configuraciones geométricas variables dentro de un espacio de diseño definido. En el contexto de la ingeniería estructural, el modelado paramétrico permite representar una familia de estructuras mediante un conjunto reduci-

do de parámetros geométricos y topológicos, facilitando la exploración de alternativas de diseño y su posterior evaluación estructural. A diferencia del modelado geométrico tradicional, en el cual cada variante debe construirse manualmente, el enfoque paramétrico permite automatizar la generación de múltiples configuraciones a partir de la modificación controlada de parámetros, incrementando significativamente la eficiencia del proceso de diseño.

En la presente investigación, el modelado paramétrico se desarrolla utilizando la plataforma Rhinoceros 3D junto con su entorno visual de programación Grasshopper, el cual permite definir relaciones geométricas, lógicas y matemáticas entre los distintos componentes del modelo estructural. Grasshopper opera mediante una estructura basada en nodos y conexiones, donde cada componente ejecuta una operación específica sobre los datos de entrada, permitiendo construir algoritmos geométricos que transforman parámetros en geometrías estructurales coherentes.

El modelo paramétrico implementado permite definir explícitamente la topología del puente reticulado a partir de parámetros tales como la luz del puente, la altura del reticulado, el número de paneles, la inclinación de las diagonales, la separación entre nodos y la configuración del sistema estructural (Warren, Pratt u otros). Estos parámetros constituyen las variables independientes del modelo, a partir de las cuales se generan automáticamente las coordenadas nodales y la conectividad entre elementos, construyendo así la geometría completa del puente para cada conjunto de valores paramétricos.

Desde el punto de vista matemático, el modelo paramétrico establece un mapeo funcional entre el espacio de parámetros P y el espacio de configuraciones estructurales X

$$X = g(P)$$

donde P es el vector de parámetros geométricos y topológicos definidos en Grasshopper, y X representa la configuración estructural resultante, expresada en términos de nodos, elementos y propiedades asociadas. Este mapeo permite generar automáticamente un conjunto potencialmente amplio de configuraciones estructurales mediante variaciones sistemáticas de los parámetros.

Una de las principales ventajas del uso de Grasshopper en este contexto es su capacidad para integrarse con otros entornos computacionales, permitiendo la exportación automática de geometrías hacia software de análisis estructural como MIDAS Civil NX. Esta integración posibilita la automatización completa del flujo de trabajo, desde la generación de la geometría hasta la evaluación estructural y el almacenamiento de resultados, eliminando la intervención manual repetitiva y reduciendo la probabilidad de errores humanos.

El modelo paramétrico también desempeña un rol clave en la generación del conjunto de datos utilizado para el entrenamiento de los modelos de aprendizaje automático. Al permitir la creación automática de miles de configuraciones estructurales distintas, el modelo paramétrico habilita la construcción de un dataset suficientemente amplio y diverso, necesario para entrenar modelos robustos capaces de generalizar adecuadamente sobre el espacio de diseño.

No obstante, el modelado paramétrico presenta también desafíos, particularmente en lo relativo a la consistencia geométrica y estructural de las configuraciones generadas. Es necesario asegurar que las geometrías producidas sean físicamente viables, evitando configuraciones con nodos desconectados, elementos de longitud nula o geometrías degeneradas que puedan provocar fallos en el análisis estructural. Por esta razón, el modelo paramétrico implementa restricciones geométricas y lógicas que garantizan la coherencia estructural básica de cada configuración generada.

En el marco de la presente investigación, el modelo paramétrico computacional desarrollado en Grasshopper constituye el núcleo generador de alternativas estructurales dentro del proceso de optimización topológica. Su integración con el algoritmo PSO y con los modelos de aprendizaje automático permite construir un flujo de trabajo completamente automatizado y coherente, en el cual la generación, evaluación y selección de configuraciones estructurales se realiza de manera sistemática y eficiente.

De este modo, el modelo paramétrico no es únicamente una herramienta de representación geométrica, sino un componente esencial del sistema computacional propuesto, que articula la interacción entre diseño, análisis estructural y optimización bioinspirada dentro de un marco metodológico integrado.




Figura 2.17: Flujo de trabajo paramétrico con Rhino y Grasshopper para diseño computacional. Fuente: Adaptado de Chronis, Liapi y Sibetheros (2012)

2.9. Estado del arte

La aplicación de algoritmos de optimización bioinspirada en ingeniería estructural ha experimentado un crecimiento significativo durante las últimas dos décadas, impulsada por la necesidad de abordar problemas de diseño caracterizados por alta

no linealidad, múltiples restricciones y espacios de búsqueda no convexos. Entre estos algoritmos, el Particle Swarm Optimization (PSO) ha sido ampliamente adoptado debido a su simplicidad, eficiencia computacional relativa y capacidad para converger hacia soluciones competitivas en problemas de gran dimensión (Kennedy & Eberhart, 1995; Kaveh, 2014). Diversos estudios han demostrado su efectividad en la optimización de secciones transversales, configuraciones estructurales y parámetros de diseño en pórticos, armaduras y sistemas reticulados.

Sin embargo, el principal desafío asociado al uso del PSO en problemas estructurales reales radica en el elevado costo computacional de la evaluación repetitiva de la función objetivo, que usualmente implica la ejecución de análisis estructurales mediante el método de los elementos finitos. En contextos donde se requieren miles de evaluaciones para alcanzar la convergencia, este costo puede volverse prohibitivo, limitando la aplicabilidad del algoritmo a problemas académicos o de pequeña escala.

Con el objetivo de mitigar esta limitación, se ha propuesto el uso de modelos sustitutos basados en aprendizaje automático, particularmente redes neuronales profundas (Deep Neural Networks, DNN), para aproximar la respuesta estructural. Estas redes son capaces de aprender relaciones no lineales complejas entre variables de diseño y respuestas estructurales a partir de grandes volúmenes de datos generados mediante simulaciones o experimentos (Goodfellow et al., 2016). En ingeniería estructural, las DNN han sido utilizadas para predecir desplazamientos, tensiones, factores de seguridad y modos de falla, con errores relativos generalmente inferiores al 5 % cuando se entrenan con datasets adecuados (Sun et al., 2020).

La integración de PSO con modelos basados en DNN ha dado lugar a enfoques híbridos orientados a acelerar el proceso de optimización estructural. En estos enfoques, el modelo neuronal se utiliza como evaluador rápido de la función objetivo y de las restricciones durante la fase exploratoria del PSO, reduciendo drásticamente el número de análisis FEM requeridos. Posteriormente, las soluciones más prometedoras son validadas mediante análisis estructural de alta fidelidad. Este esquema permite conservar la robustez del PSO para explorar el espacio de diseño, mientras se aprovecha la eficiencia computacional de las DNN.

Estudios recientes reportan que la integración PSO + DNN puede reducir el tiempo total de optimización entre un 60 % y un 90 %, sin pérdidas significativas de precisión en la identificación de soluciones cercanas al óptimo global (Zhao et al., 2019; Wang et al., 2021). Estos resultados evidencian el potencial de los enfoques híbridos para trasladar técnicas avanzadas de optimización desde el ámbito académico hacia aplicaciones reales de ingeniería.

No obstante, la mayoría de los trabajos existentes se centran en problemas estructu-

rales genéricos, como pórticos planos, armaduras bidimensionales pequeñas o elementos mecánicos, y no abordan explícitamente la aplicación a puentes reticulados reales diseñados conforme a normativas específicas. Asimismo, muchos estudios emplean representaciones vectoriales simplificadas de las estructuras, lo que limita la capacidad de los modelos para capturar la complejidad topológica inherente a sistemas reticulados de gran escala.

En el contexto latinoamericano, y particularmente en el Perú, la literatura sobre la integración de PSO y DNN en el diseño estructural es aún incipiente. La práctica profesional continúa basándose predominantemente en enfoques deterministas tradicionales, con escasa incorporación de técnicas avanzadas de optimización y aprendizaje automático. Esta situación evidencia una brecha significativa entre el estado del arte internacional y la práctica local, lo que justifica la necesidad de investigaciones que adapten y validen estos enfoques en el contexto normativo y constructivo del país. En este marco, la presente investigación se posiciona como una contribución orientada a integrar de manera sistemática un algoritmo de optimización bioinspirada (PSO) con modelos de aprendizaje profundo (DNN) para la optimización topológica de puentes reticulados metálicos reales, diseñados conforme a la normativa AASHTO LRFD. Este enfoque busca no solo mejorar la eficiencia estructural y computacional del proceso de diseño, sino también establecer un puente entre los desarrollos teóricos recientes y su aplicación práctica en ingeniería civil.

Capítulo 3

FORMULACIÓN DEL PROBLEMA

3.1. Variables de diseño

En la presente investigación, las variables de diseño corresponden a los parámetros topológicos, geométricos y mecánicos del puente reticulado metálico que pueden ser modificados por el algoritmo de optimización bioinspirada con el fin de obtener configuraciones estructurales más eficientes, manteniendo el cumplimiento de los requisitos normativos de resistencia, estabilidad y servicio.

Dado que el objetivo principal del estudio es la optimización topológica discreta de la superestructura del puente, el conjunto de variables de diseño se define principalmente sobre la presencia o ausencia de elementos estructurales dentro de una retícula base previamente establecida, así como sobre ciertos parámetros geométricos y de sección transversal asociados a dichos elementos.

Las variables de diseño se agrupan en los siguientes tres conjuntos.

3.2. Variables geométricas

Las variables geométricas controlan la configuración espacial global del puente reticulado y se consideran continuas dentro de rangos previamente establecidos por restricciones funcionales, constructivas y normativas. En el presente estudio se consideran, entre otras, las siguientes variables:

- Altura del reticulado $h \in [h_{\text{mín}}, h_{\text{máx}}]$.
- Separación longitudinal entre nodos $s \in [s_{\text{mín}}, s_{\text{máx}}]$.
- Longitud del panel $L_p \in [L_{p,\text{mín}}, L_{p,\text{máx}}]$.

Estas variables permiten explorar configuraciones más esbeltas o más robustas del sistema, influyendo directamente en la rigidez global, la distribución de esfuerzos y la estabilidad estructural.

3.3. Variables de sección transversal

Las variables de sección transversal definen las propiedades mecánicas de los elementos estructurales activos y se seleccionan a partir de un conjunto discreto de perfiles comerciales disponibles. Estas variables incluyen:

- Área de la sección transversal A_i .
- Momento de inercia I_i .
- Tipo de perfil (tubular, perfil H, ángulo, etc.).

Formalmente:

$$A_i \in A_1, A_2, A_3 \dots A_k$$

3.4. Vector de variables de diseño

El vector completo de variables de diseño se expresa de forma compacta como:

$$x = x_1, x_2, \dots, x_{Ne}, h, S, LP, A_1, A_2, \dots, A_K$$

donde cada componente representa una decisión de diseño asociada a la topología, geometría o sección transversal del sistema estructural.

3.5. Implementación computacional

En la implementación computacional del problema, las variables topológicas se codifican como un vector binario dentro del algoritmo PSO binario, mientras que las variables geométricas y de sección se representan mediante variables continuas o discretizadas según corresponda. Cada conjunto de variables es exportado automáticamente desde el entorno paramétrico (Grasshopper) hacia el modelo de elementos finitos (MIDAS Civil), donde se evalúa la respuesta estructural correspondiente. Posteriormente, dicha respuesta es utilizada por el algoritmo de optimización para actualizar las variables de diseño en la siguiente iteración.

3.6. Función objetivo

En el presente estudio se busca identificar configuraciones topológicas del puente reticulado metálico que minimicen el consumo total de acero estructural, manteniendo simultáneamente el cumplimiento de los estados límite últimos y de servicio exigidos por la normativa vigente y garantizando la viabilidad constructiva de la solución resultante.

Por tanto, la función objetivo principal se establece como la minimización del peso total de la superestructura del puente, expresada como:

$$f_x = W_x = \sum_{i=1}^{N_e} x_i \rho A_i L_i$$

donde x_i representa la activación del elemento estructural i dentro de la retícula base, A_i su área de sección transversal, L_i su longitud y ρ la densidad del acero.

Este criterio permite comparar directamente distintas configuraciones topológicas en términos de eficiencia material, favoreciendo aquellas que transmiten las acciones de manera más directa y con menor cantidad de material.

3.7. Restricciones

Las configuraciones estructurales generadas durante el proceso de optimización deben satisfacer simultáneamente un conjunto de restricciones que garantizan la seguridad estructural, la funcionalidad del puente y la viabilidad constructiva de las soluciones obtenidas. Estas restricciones se formulan con base en criterios normativos, principios de estabilidad estructural y requerimientos geométricos del proyecto.

Las restricciones se agrupan en restricciones de resistencia, servicio, estabilidad, constructibilidad y topología mínima.

3.7.1. Restricciones de resistencia

Para cada elemento estructural activo i , las solicitaciones internas obtenidas del análisis por elementos finitos deben ser menores o iguales a sus capacidades resistentes:

$$Ratio = \frac{D}{C} < 1,00$$

Donde:

D = demandas y/o solicitación.

C = Capacidad de resistencia.

En particular:

- Para elementos a tracción:

$$\frac{N_i}{\phi T_{n,i}} < 1,00$$

- Para elementos a compresión:

$$\frac{N_i}{\emptyset P_{n,i}} < 1,00$$

- Para elementos a Flexión:

$$\frac{N_i}{\emptyset M_{n,i}} < 1,00$$

Donde $\emptyset$ es el factor de resistencia normativo.

3.7.2. Restricciones de servicio

Los desplazamientos máximos del puente deben mantenerse dentro de límites admisibles para garantizar el confort del usuario y la integridad funcional de la estructura:

$$\delta_{max} < \frac{L}{1000}$$

Esta verificación se da con la carga viva vehicular indicada por el código de diseño.

3.7.3. Restricciones de estabilidad

Los elementos sometidos a compresión deben ser estables frente a pandeo elástico y plástico:

$$\frac{N_i}{N_{cr,i}} < 1,00$$

donde N_{cr} es la carga crítica de pandeo del elemento i, determinada en función de su esbeltez, condiciones de apoyo y propiedades mecánicas.

Capítulo 4

METODOLOGÍA PROPUESTA

Este capítulo describe la metodología computacional desarrollada para llevar a cabo la optimización topológica discreta de puentes reticulados metálicos, integrando modelado paramétrico, análisis estructural por elementos finitos, algoritmos de optimización bioinspirada y modelos de aprendizaje automático. El enfoque propuesto permite explorar de manera sistemática un amplio espacio de configuraciones estructurales y conducir el proceso hacia soluciones eficientes y normativamente viables.

La metodología se estructura en cinco etapas principales: definición del modelo paramétrico, formulación del problema de optimización, evaluación estructural, proceso de optimización y validación de resultados.

4.1. Modelamiento Paramétrico con Rhino–Grasshopper

El modelo paramétrico constituye la base geométrica y topológica del proceso de optimización propuesto.

En el presente estudio, la superestructura del puente reticulado se define mediante un entorno de modelado paramétrico desarrollado en Rhinoceros 3D y su complemento Grasshopper, el cual permite generar automáticamente un conjunto amplio de configuraciones estructurales a partir de un número reducido de parámetros de control.

La geometría global del puente se parametriza en función de su luz total, número de paneles, altura del reticulado, separación entre nodos, disposición de diagonales y tipo de reticulado (por ejemplo, Warren, Pratt o variantes híbridas).

Estos parámetros se controlan mediante deslizadores y componentes algorítmicos dentro de Grasshopper, lo que permite explorar de manera continua el espacio de posibles configuraciones geométricas y topológicas.

El uso de Grasshopper permite además establecer relaciones explícitas entre los parámetros geométricos, garantizando que las configuraciones generadas cumplan auto-

máticamente con restricciones geométricas básicas, tales como la simetría longitudinal, la compatibilidad entre longitudes de paneles y la alineación de nodos, evitando así la generación de geometrías no válidas desde el punto de vista estructural o constructivo.

4.1.1. Parametrización de la geometría del puente

La parametrización de la geometría del puente se implementa mediante un algoritmo visual desarrollado en Grasshopper, complemento de programación visual integrado en Rhinoceros 3D, que permite describir el proceso de generación geométrica como una secuencia de transformaciones algorítmicas aplicadas a un conjunto reducido de parámetros de entrada. Este enfoque permite representar explícitamente las relaciones entre las variables geométricas del sistema y la configuración estructural resultante, garantizando que cada modificación paramétrica produzca automáticamente una nueva geometría coherente sin necesidad de intervención manual. Grasshopper opera bajo el paradigma de programación orientada a flujos de datos, en el cual cada componente ejecuta una operación matemática, lógica o geométrica y transmite su resultado a otros componentes a través de conexiones que representan dependencias funcionales. Cuando uno de los parámetros de entrada se modifica, el sistema se reevalúa de manera reactiva y propaga automáticamente el cambio a lo largo de toda la red de operaciones, generando una nueva instancia geométrica del modelo. Este mecanismo constituye la base del proceso de exploración paramétrica y permite al algoritmo de optimización interactuar directamente con el modelo geométrico.

En el presente estudio, los parámetros geométricos fundamentales la luz total del puente, el número de paneles, la altura del reticulado, el tipo de reticulado y la posición de los apoyos se introducen como variables de control dentro del entorno Grasshopper.

Estos parámetros alimentan expresiones matemáticas que definen la separación entre nodos, las coordenadas espaciales de los puntos que conforman los cordones superior e inferior, y la orientación de los elementos internos del reticulado. De este modo, la geometría del puente se define de manera completamente algorítmica y depende exclusivamente de los valores de entrada.

A partir de estos parámetros, el algoritmo genera automáticamente las coordenadas de los nodos principales y construye las conexiones entre ellos que representan los cordones, montantes y diagonales del sistema estructural. La organización interna de estos elementos se gestiona mediante estructuras jerárquicas de datos que permiten identificar de manera unívoca cada nodo y cada barra dentro del modelo, estableciendo una correspondencia directa entre la geometría generada y las variables topológicas empleadas por el algoritmo de optimización.

El tipo de reticulado se introduce como una variable categórica que controla la

orientación y presencia inicial de los elementos internos. Esto permite generar distintas configuraciones base por ejemplo, Warren, Pratt o configuraciones híbridas y evaluar su influencia sobre el desempeño estructural y la eficiencia material del sistema.

El algoritmo puede activar o desactivar conjuntos completos de elementos en función de esta variable, manteniendo siempre la consistencia geométrica del modelo.

Una vez definida la geometría básica, el algoritmo genera una retícula base que contiene todas las barras potenciales del sistema. Cada una de estas barras se asocia a una variable binaria que indica su presencia o ausencia en la configuración estructural final. Esta codificación permite que el proceso de optimización actúe directamente sobre la conectividad del sistema, eliminando o conservando elementos según su contribución al desempeño estructural.

Grasshopper gestiona estas operaciones de manera determinista y reproducible, de modo que una misma combinación de parámetros siempre conduce a la misma geometría. Esta propiedad es fundamental para garantizar la trazabilidad del proceso de optimización y para poder comparar de manera objetiva distintas configuraciones generadas por el algoritmo.

En este contexto, Grasshopper no se utiliza únicamente como una herramienta de modelado geométrico, sino como un entorno computacional que formaliza el proceso de diseño estructural como un algoritmo generativo. Esta formalización permite acoplar el modelo geométrico con el algoritmo de optimización bioinspirada y con el análisis estructural por elementos finitos, estableciendo un flujo de trabajo coherente que integra parametrización, evaluación estructural y optimización dentro de un mismo marco computacional.

De este modo, la parametrización implementada en Grasshopper constituye el primer eslabón del flujo metodológico propuesto, ya que traduce los vectores de variables de diseño generados por el algoritmo de optimización en configuraciones estructurales explícitas que pueden ser evaluadas desde el punto de vista ingenieril, permitiendo así explorar de manera sistemática el espacio de diseño del puente reticulado.




Figura 4.1: Algoritmo de Puente Reticulado Multivariable en Grasshopper. Fuente: Elaboración Propia.




Figura 4.2: Input de data para puente. Fuente: Elaboración Propia.




Figura 4.3: Codificación y visualización 3d de puente reticulado Gh/Rhino. Fuente: Elaboración Propia.




Figura 4.4: Estructura Generada por Grasopper, Puente Reticulado Fuente: Elaboración Propia.

4.1.2. Integración paramétrica con el modelo de elementos finitos

La integración entre el modelo paramétrico desarrollado en Grasshopper y el modelo estructural de elementos finitos constituye el vínculo fundamental entre el espacio de diseño generado algorítmicamente y la evaluación física del comportamiento estructural. En el presente estudio, esta integración permite traducir automáticamente cada configuración geométrica y topológica generada por el algoritmo en un modelo estructural verificable mediante análisis por elementos finitos, sin intervención manual

y manteniendo consistencia entre geometría, propiedades mecánicas y condiciones de borde.

Cada instancia geométrica producida en Grasshopper se convierte en un conjunto explícito de nodos, elementos y propiedades estructurales que se exportan al entorno de análisis estructural. Esta traducción se realiza mediante un procedimiento automático que transforma las entidades geométricas puntos y líneas en nodos estructurales y elementos tipo frame, respectivamente, conservando su conectividad y su posición espacial.

Las propiedades mecánicas de los elementos, tales como el módulo de elasticidad, la densidad del material y las secciones transversales, se asignan de acuerdo con el catálogo de perfiles considerado en el estudio. Esta asignación se realiza de forma paramétrica, permitiendo que el algoritmo de optimización modifique automáticamente la selección de secciones cuando así lo requiera el proceso de búsqueda.

Asimismo, se definen de manera automática las condiciones de borde del sistema estructural, incluyendo la ubicación y el tipo de apoyos, así como los grados de libertad restringidos en cada nodo.

Las acciones externas y combinaciones de carga se introducen conforme al esquema de cargas considerado en el proyecto, garantizando que todas las configuraciones generadas se evalúen bajo condiciones de solicitación consistentes.

El modelo estructural resultante se analiza mediante el método de los elementos finitos, obteniendo como salida los desplazamientos nodales, los esfuerzos internos de cada elemento y los factores de utilización respecto a los límites normativos. Estos resultados constituyen la base para la evaluación de la función objetivo y de las restricciones definidas en el Capítulo III.

La integración paramétrica garantiza que cada modificación introducida por el algoritmo de optimización ya sea la activación o eliminación de elementos, la modificación de la geometría o el cambio de secciones se refleje inmediatamente en el modelo estructural y sea evaluada de manera coherente. Este acoplamiento evita errores de transcripción, reduce significativamente el tiempo de análisis y permite explorar un gran número de configuraciones dentro de un marco computacional controlado.

En este sentido, la integración paramétrica no solo automatiza la generación del modelo estructural, sino que transforma el análisis estructural en un componente activo del proceso de optimización, permitiendo que la respuesta física del sistema guíe directamente la evolución de las soluciones generadas por el algoritmo.

De este modo, el modelo de elementos finitos deja de ser una herramienta de verificación posterior y se convierte en un componente esencial del proceso de diseño, integrándose de manera dinámica con el modelado paramétrico y la optimización bio-

inspirada dentro de una única metodología computacional coherente.




Figura 4.5: interoperabilidad Grasshopper y Midas Civil NX. Fuente: Elaboración Propia.

4.1.3. Ingeniería Estructural y Normatividad.

Filosofía de Diseño

Los puentes se deben diseñar considerando los estados límites especificados a fin de lograr los objetivos de constructibilidad, seguridad y serviciabilidad, considerando debidamente los aspectos relacionados con la inspeccionabilidad, economía y estética.

Independientemente del tipo de análisis utilizado, la Ecuación 2.3.2.2.1-1 se deberá satisfacer para todas las solicitaciones y combinaciones de solicitaciones especificadas, sin tener en cuenta el tipo de análisis usado.

La Resistencia de los elementos y conexiones son determinados teniendo en cuenta el comportamiento inelástico (ductilidad), aunque los efectos de las fuerzas han sido calculados usando el análisis elástico.

Estados Límites

Cada uno de los elementos y conexiones satisface la Ecuación 2.3.2.2.1-1 para cada uno de los estados límites. Para los estados límites de servicio y correspondientes a eventos extremos los factores de resistencia se deben tomar igual a 1.0, todos los estados límites se deben considerar de igual importancia.

$$\sum \eta_i \gamma_i Q_i \leq \phi R_n = R_r \dots \dots \dots, 2, 3, 2, 2, 1 - 1$$

Donde: Para cargas para las cuales un valor máximo de γ_i es apropiado:

$$\eta_i = \eta_D \eta_R \eta_I \geq 0,95 \dots \dots \dots, 2, 3, 2, 2, 1 - 2$$

Para cargas para las cuales un valor mínimo de γ_i es apropiado:

$$\eta_i = \frac{1}{\eta_D \eta_R \eta_I} \leq 1, 0, \dots, 2, 3, 2, 2, 1 - 3$$

Donde:

γ_i = factor de carga: multiplicador de base estadística que se aplica a las solicitaciones.

ϕ = factor de resistencia: multiplicador de base estadística que se aplica a la resistencia nominal, según lo especificado en las secciones 5, 6, 7, 8, 10, 11 y 12.

η_i = factor de modificación de las cargas: factor relacionado con la ductilidad, redundancia e importancia operativa.

η_D = factor relacionado con la ductilidad, según lo especificado en el artículo 1.3.3 (AASHTO-LRFD).

η_R = factor relacionado con la redundancia, según lo especificado en el artículo 1.3.4 (AASHTO-LRFD).

η_I = factor relacionado con la importancia, según lo especificado en el artículo 1.3.5 (AASHTO-LRFD).

Q_i = Solicitación.

R_n = Resistencia Nominal.

R_r = Resistencia Mayorada: ϕR_n

La ductilidad, la redundancia y la importancia operacional son aspectos significativos que afectan el factor de seguridad de los puentes. Los dos primeros aspectos relacionan directamente a la resistencia mecánica, el último aspecto se refiere a las consecuencias que ocurren cuando un puente se encuentra fuera de servicio. Como se ve, estos aspectos referentes a las cargas son arbitrarios. Sin embargo, esto constituye un primer esfuerzo para el desempeño esperado. Una aproximación subjetiva, debido a la ausencia de información más precisa es que cada efecto, excepto para fatiga y fractura, deba ser estimado como un $\pm 5\%$ geométricamente acumulado. Con el tiempo una cuantificación mejorada de estos aspectos y su interacción y la sinergia del sistema podrían ser alcanzadas. Posiblemente esto conducirá a un arreglo de la Ecuación 2.3.2.2.1-1 (1.3.2.1-1 AASHTO) en el cual esos efectos podrían aparecer sobre uno de los lados o en ambos lados de la ecuación.

A. Estado límite de Servicio

El estado límite de servicio se debe considerar como restricciones impuestas a las tensiones, deformaciones y anchos de fisura bajo condiciones de servicio regular; este estado proporciona ciertos requisitos basados en la experiencia que no siempre se pueden derivar exclusivamente a partir de consideraciones estadísticas o de resistencia.

B. Estado límite de Fatiga y Fractura

El estado límite de fatiga se debe considerar como restricciones impuestas al rango

de tensiones que se da como resultado de un único camión de diseño ocurriendo el número anticipado de ciclos del intervalo de tensión. El estado límite de fractura se debe considerar como un conjunto de requisitos de sobre resistencia de materiales de las Especificaciones sobre Materiales de AASHTO. La intención del estado límite de fatiga es limitar el crecimiento de las fisuras bajo cargas repetitivas, a fin de impedir la fractura durante el período de diseño del puente.

C. Estado límite de Resistencia

Se debe considerar el estado límite de resistencia para garantizar que se provee resistencia y estabilidad, tanto local como global, para resistir las combinaciones de cargas estadísticamente significativas especificadas que se anticipa que el puente experimentará durante su período de diseño. Bajo el estado límite de resistencia se pueden producir tensiones muy elevadas y daños estructurales, pero se espera que la integridad estructural global se mantenga.

D. Estado límite de evento extremo

El estado límite de evento extremo ha sido considerado para asegurar la supervivencia estructural del puente durante un sismo importante o durante inundaciones, o colisión de vehículos, o bajo condiciones severas de socavación.

Ductilidad

El sistema estructural de un puente se debe dimensionar y detallar de manera de asegurar el desarrollo de deformaciones inelásticas significativas y visibles en los estados límites de resistencia y correspondientes a eventos extremos antes de la falla. Se puede asumir que los requisitos de ductilidad se satisfacen para una estructura de acero en la cual la resistencia de una conexión es mayor o igual que 1.3 veces la máxima solicitación impuesta a la conexión por la acción inelástica de los elementos adyacentes.

Para el estado límite de resistencia:

$\eta_D: \leq 1.05$ para elementos y conexiones no dúctiles

= 1.00 para diseños y detalles convencionales que cumplen con las Especificaciones del AASHTO – LRFD.

≤ 0.95 para elementos y conexiones para los cuales se han especificado medidas adicionales para mejorar la ductilidad más allá de lo requerido por las Especificaciones del AASHTO – LRFD.

Para todos los demás estados límites:

$\eta_D = 1,00$

Redundancia

A menos que existan motivos justificados para evitarlas, se deben usar estructuras continuas y con múltiples recorridos de cargas (camino de carga en el interior de la estructura).

Los principales elementos y componentes cuya falla se anticipa provocará el colapso del puente, por lo tanto, se diseñará como elementos de falla crítica y el sistema estructural asociado se definirá como sistema no redundante. Alternativamente, los elementos de falla crítica traccionados se pueden diseñar como de fractura crítica.

Los elementos y componentes cuya falla se anticipa no provocará el colapso del puente se deben diseñar como elementos de falla no crítica y el sistema estructural asociado se definirá como sistema redundante.

Para el estado límite de resistencia:

$\eta_R \leq 1.05$ para elementos no redundantes.

$= 1.00$ para los niveles convencionales de redundancia.

≥ 0.95 para los niveles excepcionales de redundancia.

Para todos los demás estados límites:

$\eta_R := 1.00$

Para cada combinación de carga y estado límite considerado, la clasificación de redundancia de los miembros, es decir si son redundantes o no redundantes, estará basado en la contribución de los miembros a la seguridad del puente.

4.1.4. Importancia Operativa

Se aplicará exclusivamente a los estados límites de resistencia y los correspondientes a eventos extremos.

Para el estado límite de resistencia:

$\eta_I \leq 1.05$ para puentes importantes.

$= 1.00$ para puentes típicos.

≥ 0.95 para puentes de relativamente poca importancia.

Para todos los demás estados límites:

$\eta_I := 1.00$

La clasificación operativa del puente será efectuada por el personal responsable de la red vial afectada y conocedor de sus necesidades operativas. El puente “Alto Perú” se ha considerado dentro de los puentes Críticos, es decir que requiere ser abierto a todo tráfico una vez que han sido inspeccionados después del evento de diseño. Para el análisis y diseño estructural del puente Alto Peru de tipo Reticulado, Se tomarán las recomendaciones del Manual de Puentes del MTC – 2018 y de la norma AASHTO

LRFD Bridge Design Specifications 9th Edition, con la finalidad de cumplir con los objetivos de constructibilidad, seguridad y servicialidad que debe tener toda estructura de puente, así como con la debida consideración en lo que se refiere a inspección, economía y estética.



Figura 4.6: Manual de Puentes del MTC y norma AASHTO LRFD. Fuente: Elaboración propia.

Normatividad

El diseño de las estructuras de puentes, está basado en las partes aplicables de las siguientes Normas Técnicas y Reglamentos, teniendo en cuenta un periodo de retorno de 1000 años:

- AASHTO LRFD Bridge Design Specifications. 9th Edition, 2020.
- AASHTO Guide Specifications for LRFD Seismic Bridge Design, 2011.
- CEB – FIP Model Code 1990 for Concrete Structures, 1993.
- Manual de Diseño de Puentes. Ministerio de Transportes y Comunicaciones, 2018.
- ACI 318-11 Specification for Structural Concrete for Buildings.

Materiales

a) Concreto:

Las diferentes calidades de concreto a utilizar tendrán las siguientes resistencias mínimas a los 28 días:

Concreto en Losa de tablero

Resistencia especificada a compresión: $f'_c = 35 \text{ MPa}$

Peso específico del concreto: $\gamma_c = 25 \text{ kN/m}^3$

Módulo elástico: $E_c = 27,520 \text{ MPa}$

Coefficiente de Poisson: $\mu = 0,20$

Coefficiente de dilatación térmica: $C_c = 10,80 \times 10^{-6} \text{ mm/mm/C}$

Concreto en estribos: Zapata, pantalla, alas, contrafuerte, losa de aproximación,

Resistencia especificada a compresión: $f'_c = 28 \text{ MPa}$

Peso específico del concreto: $\gamma_c = 25 \text{ kN/m}^3$

Módulo elástico: $E_c = 25,100 \text{ MPa}$

Coefficiente de Poisson: $\mu = 0,20$

Coefficiente de dilatación térmica: $C_c = 10,80 \times 10^{-6} \text{ mm/mm/C}$

Concreto en Dado

Resistencia especificada a compresión: $f'_c = 100 \text{ MPa} + 30 \% PG$

Peso específico del concreto: $\gamma_c = 24 \text{ kN/m}^3$

Módulo elástico: $E_c = 14,710 \text{ MPa}$

Coefficiente de Poisson: $\mu = 0,20$

Coefficiente de dilatación térmica: $C_c = 10,80 \times 10^{-6} \text{ mm/mm/C}$

b) Acero

Acero estructural

Tipo de acero: ASTM A709 Gr.50

Módulo elástico: $E_s = 200,000 \text{ MPa}$

Peso específico: $g_s = 77,09 \text{ kN/m}^3$

Resistencia a la fluencia: $F_y = 345 \text{ MPa}$

Resistencia última: $F_u = 450 \text{ MPa}$

Acero de refuerzo pasivo

ESTRIBO, ALETA, LOSA DE APROXIMACION, LOSA Y VEREDA:

Tipo de acero: ASTM A-615 Gr. 60.

Módulo elástico: $E_p = 200,000 \text{ MPa}$

Peso específico: $g_s = 77.09 \text{ kN/m}^3$

Resistencia a la fluencia: $f_y = 420 \text{ MPa}$

4.1.5. Solicitaciones

(4.1.5.1) Cargas permanentes

Son aquellas que actúan durante toda la vida útil de la estructura sin variar significativamente, o que varían en un solo sentido hasta alcanzar un valor límite. Corresponden a este grupo el peso propio de los elementos estructurales y las cargas muertas adicionales como el peso de la superficie de rodadura o las barandas. También se consideran cargas permanentes el empuje de tierra, los efectos de retracción y fluencia, las deformaciones permanentes originadas por los procedimientos de construcción y los efectos de asentamientos de apoyo.

a) PESO PROPIO Y CARGAS MUERTAS (DC)

Se considera el peso propio de los componentes estructurales tomando en cuenta los siguientes pesos específicos:

- Concreto Armado 2.5t/m³
- Acero Estructural 7.85 t/m³
- Peso de conexiones y componentes estructurales menores, 15 % del peso total.




Figura 4.7: Asignación de Carga de Asfalto. Fuente: Elaboración Propia.

- Peso de vereda igual a 0.300 t/m² (ancho de vereda)
- Peso del asfalto de espesor a 5cm igual a 0.115 t/m² (ancho de calzada)




Figura 4.8: Asignación de Carga de Vereda. Fuente: Elaboración Propia.

b) ACCIONES REOLÓGICAS (CR, SH)

Se considera las acciones debido a la retracción y fluencia del concreto para el diseño del puente, considerándose un coeficiente para el acortamiento de fragua y un coeficiente para el creep dependientes del tiempo con las variaciones y parámetros tal cual lo indica la norma CEB-FIP-90.




Figura 4.9: Coeficiente de flujo plástico para la losa. Fuente: Elaboración Propia.





Figura 4.10: Coeficiente de flujo plástico para la losa. Fuente: Elaboración Propia.

(4.1.5.2) Cargas Variables

a) CARGA VIVA VEHICULAR (LL+IM)

Aquí se incluyen todos los efectos de la sobrecarga vehicular estipulados en el AASHTO-LRFD. Se considera para ello un impacto del 33 %.






Figura 4.11: Camión HL-93. Fuente: Elaboración Propia.

Sobrecarga Distribuida (Carga de Carril de Diseño)

Se considerará una sobrecarga de 0.64 kip/ft (954 kgf/m), uniformemente distribuida en dirección longitudinal sobre aquellas porciones del puente en las que produzca un efecto desfavorable. Se supondrá que esta sobrecarga se distribuye uniformemente sobre un ancho de 10.0 ft en dirección transversal. Esta sobrecarga se aplicará también sobre aquellas zonas donde se ubique el camión o el tándem de diseño. No se considerarán efectos dinámicos para esta sobrecarga.

Área de contacto de los Neumáticos

El área de contacto de una rueda consistente de una o dos neumáticos se asumirá como un rectángulo de 20.0in de ancho en dirección transversal del puente y 10.0in en el sentido del eje longitudinal del mismo.

Se supondrá que los neumáticos ejercen una presión uniforme sobre el área de contacto. Se supondrá que la presión de los neumáticos se distribuye de la siguiente manera:

- En superficies continuas, uniformemente sobre el área de contacto especificada, y
- En superficies discontinuas, uniformemente sobre el área de contacto real dentro de la huella, aumentando la presión en función de la relación entre el área de contacto especificada y la real.

Para el diseño de tableros ortotrópicos y superficies de desgaste sobre los tableros ortotrópicos, las ruedas delanteras se asumirán como un simple rectángulo cuyo ancho y largo sean de 10.0in como se especifica en el Artículo 2.4.3.2.4.1 (3.6.1.4.1 AASHTO).

Presencia Múltiples de Sobrecargas

Presencia múltiple no se aplicarán al estado límite de fatiga, solo se aplicará para cuando se utilice un camión de diseño independiente del número de carriles que se tenga en el puente.

**Nota: si en lugar de emplear la ley de momentos y el método estático, se aplican los factores de distribución de carga móvil para carril único; las solicitaciones se deberán dividir entre 1.20; ya que la presencia múltiple está incluida en las ecuaciones aproximadas para los factores de distribución de carga para carril único como para múltiples carriles cargados.*

Tabla 2.4.3.2.2.6-1 Presencia de Factores Múltiples, m

(3.6.1.1.2-1 AASHTO)

Número de Vías Cargadas	Presencia de Factores Múltiples, m
1	1.20
2	1.00
3	0.85
> 3	0.65

Para el presente caso se tiene más de 2 vías cargadas por lo que el factor de presencia múltiple “m” será 1.00.

Aplicación de las cargas vehiculares de diseño

Ubicación Longitudinal:

En la dirección longitudinal, el puente será cargado en forma continua o discontinua según resulte más crítico para el efecto en estudio, considerando los siguientes casos:

- Tándem de diseño más carga distribuida.
- Camión de diseño más carga distribuida. La distancia entre los ejes de 32.0 kips, ver Artículo 2.4.3.2.2.2, será aquella que produzca el efecto más desfavorable en cada caso.

Ubicación Transversal:

Tanto los carriles de diseño como el ancho cargado de 10.0 ft cada carril se deberá ubicar de manera que produzcan solicitaciones extremas. El camión y tándem de diseño se deberá ubicar transversalmente de manera que ninguno de los centros de las cargas de rueda esté a menos de:

- Para el diseño del voladizo del tablero – 1.0 ft. a partir de la cara del sardinel o de la baranda, y

- Para el diseño de todos los demás componentes – 2.0 ft. a partir del borde del carril de diseño.

A menos que se especifique lo contrario, las longitudes de los carriles de diseño o de las partes de los carriles de diseño que contribuyen a la sollicitación extrema bajo consideración, se deberán cargar con la carga del carril de diseño.

Carga para la evaluación opcional de la Deflexión por sobrecarga

A menos que se disponga de otro modo, ver Artículo 2.9.1.4.4.5.1b (2.5.2.6.2 AASH-TO), la deflexión se deberá tomar como el mayor valor entre:

- La que resulta del camión de diseño solamente, o
- La que resulta del 25 por ciento del camión de diseño considerado juntamente con la carga del carril de diseño.

Define User Defined Vehicular Load

Load Type

☒ Truck/Lane

☐ Legal/Permit Load

☐ Train Load

☐ Permit Truck

Vehicular Load Properties

Vehicular Load Name : SC +0.25Camion

Truck Load

Lane Load

Truck Load

P#	D#

Add

No	Load(kgf)	Spacing(m...)
1	910	4270
2	3630	4270
3	3630	9140

Insert

Modify

Delete

Lane Load

w 0.95 kgf/mm

PL 0 kgf

PLM 0 kgf

PLV 0 kgf

Figura 4.12: Vehículo Deflexión AASHTO LRFD (Sobre Carga+25 % del Camión).
Fuente: Elaboración propia.

B) Carga Peatonal

Esta carga es de 0.360t/m² y se representa en todo el ancho de las veredas.




Figura 4.13: Carga peatonal sobre las veredas. Fuente: Elaboración Propia.

c) Carga viento (w):

Se asumirá que las presiones aquí especificadas son provocadas por una velocidad básica del viento, V_B , de 160 km/h. Se asumirá que la carga de viento está uniformemente distribuida sobre el área expuesta al viento. El área expuesta será la sumatoria de las áreas de todos los componentes, incluyendo el sistema de piso y las barreras, vistas en elevación y perpendiculares a la dirección de viento supuesta. Esta dirección se deberá variar para determinar las solicitaciones extremas en la estructura o en sus componentes. En el análisis se pueden despreciar las superficies que no contribuyen a la sollicitación extrema considerada. Para puentes o elementos de puentes a más de 10 m sobre el nivel del terreno o del agua, la velocidad de viento de diseño, V_{DZ} , se deberá ajustar de la siguiente manera:

$$V_{DZ} = 2.5V_0 \left(\frac{V_{30}}{V_B} \right) \ln \left(\frac{Z}{Z_0} \right) \quad (3.8.1.1-1)$$

Z_0 = friction length of upstream fetch, a meteorological wind characteristic taken as specified in Table 3.8.1.1-1 (ft)

Table 3.8.1.1—Values of V_0 and Z_0 for Various Upstream Surface Conditions

Condition	Open Country	Suburban	City
V_0 (mph)	8.20	10.90	12.00
Z_0 (ft)	0.23	3.28	8.20

V_{30} may be established from:

- Fastest-mile-of-wind charts available in ASCE 7-88 for various recurrence intervals,
- Site-specific wind surveys, and
- In the absence of better criterion, the assumption that $V_{30} = V_B = 100$ mph.




Figura 4.14: Mapa eólico del Perú. Fuente: Elaboración Propia.

Se empleará una velocidad de diseño de 100Km/h. Si las condiciones locales lo justifican, se puede seleccionar una velocidad básica del viento de diseño diferente para las combinaciones de cargas que no involucran viento actuando sobre la sobrecarga. Se asumirá que la dirección del viento de diseño es horizontal, a menos que el Artículo

3.8.3 especifique lo contrario. En ausencia de datos más precisos, la presión del viento de diseño, en MPa, se puede determinar cómo:

$$P_D = P_B \left(\frac{V_{DZ}}{V_B} \right)^2 = P_B \frac{V_{DZ}^2}{10,000} \quad (3.8.1.2.1-1)$$

P_B = base wind pressure specified in Table 3.8.1.2.1-1
(ksf)

BRIDA INFERIOR		BRIDA SUPERIOR		DIAGONAL Y MONTANTE	
VB(Km/h)=	160.00	VB(Km/h)=	160.00	VB(Km/h)=	160.00
V30(Km/h)=	75.00	V30(Km/h)=	75.00	V30(Km/h)=	75.00
Z(m)=	12.00	Z(m)=	19.50	Z(m)=	19.50
Vo(Km/h)=	13.20	Vo(Km/h)=	13.20	Vo(Km/h)=	13.20
Zo(m)=	0.07	Zo(m)=	0.07	Zo(m)=	0.07
VDZ(Km/h)=	79.57	VDZ(Km/h)=	87.08	VDZ(Km/h)=	87.08
PB(Kg/m2)=	245.00	PB(Kg/m2)=	245.00	PB(Kg/m2)=	245.00
PD(Kg/m2)=	60.60	PD(Kg/m2)=	72.58	PD(Kg/m2)=	72.58
PD(Ton/m)=	0.036	PD(Ton/m)=	0.044	PD(Ton/m)=	0.029
PS(Ton/m)=	0.018	PS(Ton/m)=	0.022	PS(Ton/m)=	0.015

La carga de viento total no deberá ser menor que 0.45Ton/m para barlovento ni 0.223Ton/m para Sotavento, por tanto, se tiene:




Figura 4.15: Cargas de viento. Fuente: Elaboración Propia.

(4.1.5.3) COMBINACIONES DE CARGA, FACTORES DE CARGA Y RESISTENCIA

La condición de diseño básica que debe cumplir cada uno de los componentes de la estructura es que su capacidad resistente no debe ser excedida por la capacidad mayorada de acuerdo al estado límite de análisis.

La solicitud mayorada es tomada como: $Q = \sum \eta_i \gamma_i Q_i$ donde η_i es el modificador de las cargas, γ_i son los factores de carga y Q_i son las solicitudes de las cargas.

Combinación de Cargas Estado Limite	DC															
	DD															
	DW															
	EH															
	EV	LL														
	ES	IM														
	EL	CE														
	PS	BR														
	CR	PL														
	SH	LS	WA	WS	WL	FR	TU	TG	SE	EQ	BL	IC	CT	CV		
RESISTENCIA I A menos que se especifique lo contrario	γ_P	1.75	1.00	--	--	1.00	0.50/1.20	γ_{TG}	γ_{SE}	--	--	--	--	--	--	--
RESISTENCIA II	γ_P	1.30	1.00	--	--	1.00	0.50/1.20	γ_{TG}	γ_{SE}	--	--	--	--	--	--	--
RESISTENCIA III	γ_P	--	1.00	1.40	--	1.00	0.50/1.20	γ_{TG}	γ_{SE}	--	--	--	--	--	--	--
RESISTENCIA IV	γ_P	--	1.00	--	--	1.00	0.50/1.20	--	--	--	--	--	--	--	--	--
RESISTENCIA V	γ_P	1.30	1.00	0.40	1.00	1.00	0.50/1.20	γ_{TG}	γ_{SE}	--	--	--	--	--	--	--
EVENTO EXTREMO I	1.0	γ_{EQ}	1.00	--	--	1.00	--	--	--	1.00	--	--	--	--	--	--
EVENTO EXTREMO II	γ_P	0.50	1.00	--	--	1.00	--	--	--	--	1.00	1.00	1.00	1.00	1.00	1.00
SERVICIO I	1.00	1.00	1.00	0.90	1.00	1.00	1.00/1.20	γ_{TG}	γ_{SE}	--	--	--	--	--	--	--
SERVICIO II	1.00	1.30	1.00	--	--	1.00	1.00/1.20	--	--	--	--	--	--	--	--	--
SERVICIO III	1.00	0.80	1.00	--	--	1.00	1.00/1.20	γ_{TG}	γ_{SE}	--	--	--	--	--	--	--
SERVICIO IV	1.00	--	1.00	0.70	--	1.00	1.00/1.20	--	1.00	--	--	--	--	--	--	--
FATIGA I Solamente LLIM & CE	--	1.50	--	--	--	--	--	--	--	--	--	--	--	--	--	--
FATIGA II- Solamente LLIM & CE	--	0.75	--	--	--	--	--	--	--	--	--	--	--	--	--	--

Figura 4.16: Factores de amplificación de cargas 1. Fuente: AASHTO LRFD-2017.

Table 3.4.1-2—Load Factors for Permanent Loads, γ_p

Type of Load, Foundation Type, and Method Used to Calculate Downdrag		Load Factor	
		Maximum	Minimum
<i>DC</i> : Component and Attachments		1.25	0.90
<i>DC</i> : Strength IV only		1.50	0.90
<i>DD</i> : Downdrag	Piles, α Tomlinson Method	1.40	0.25
	Piles, λ Method	1.05	0.30
	Drilled shafts, O'Neill and Reese (2010) Method	1.25	0.35
<i>DW</i> : Wearing Surfaces and Utilities		1.50	0.65
<i>EH</i> : Horizontal Earth Pressure			
• Active		1.50	0.90
• At-Rest		1.35	0.90
• <i>AEP</i> for anchored walls		1.35	N/A
<i>EL</i> : Locked-in Construction Stresses		1.00	1.00
<i>EV</i> : Vertical Earth Pressure			
• Overall Stability		1.00	N/A
• Retaining Walls and Abutments		1.35	1.00
• Rigid Buried Structure		1.30	0.90
• Rigid Frames		1.35	0.90
• Flexible Buried Structures			
o Metal Box Culverts, Structural Plate Culverts with Deep Corrugations, and		1.50	0.90
Fiberglass Culverts		1.30	0.90
Thermoplastic Culverts		1.95	0.90
o All others			
<i>ES</i> : Earth Surcharge		1.50	0.75

Figura 4.17: Factores de amplificación de cargas 2. Fuente: AASHTO LRFD-2017.

Los componentes y las conexiones de un puente deberán satisfacer la Ecuación 2.3.2.2.1-1 (1.3.2.1-1 AASHTO) para las combinaciones aplicables de los efectos de la fuerza extrema factorizada como se especifica en cada combinación de carga contenida en la Tabla 2.4.5.3.1-1 (3.4.1-1 AASHTO) en los estados límites siguientes:

- **RESISTENCIA I** - Combinación básica de cargas relacionada con el uso vehicular normal, sin considerar el viento.
- **RESISTENCIA II** - Combinación de cargas relacionada al uso del puente mediante vehículos de diseño especiales especificados por el propietario y/o vehículos que permiten la evaluación, sin considerar el viento.
- **RESISTENCIA III** - Combinación de cargas relacionada al puente expuesto al viento con una velocidad mayor que 90 km/h.
- **RESISTENCIA IV** - Combinación de cargas relacionada a relaciones muy altas de las solicitaciones de las cargas muertas a las cargas vivas.
- **RESISTENCIA V** Combinación de cargas relacionada al uso vehicular normal del puente considerando el viento a una velocidad de 90 km/h.

La superestructura del puente, se diseñará para los estados límite de Resistencia I y V.

- **EVENTO EXTREMO I** - Combinación de cargas incluyendo sismo. El factor de carga para carga viva EQ será determinado sobre la base de un proyecto específico.
- **EVENTO EXTREMO II** - Combinación de cargas que incluye la carga de hielo, colisión de vehículos y barcos, flujos comprobados, y ciertos eventos hidráulicos con carga viva reducida diferente a la que forma parte de la carga de colisión de vehículos, CT Los casos de flujos comprobados no serán combinados con BL, CV, CT, o IC.
- **SERVICIO I** - Combinación de cargas relacionada al uso operativo normal del puente con viento a 90 km/hr y con todas las cargas en su valor nominal (sin factorizar). También está relacionada al control de la deflexión en estructuras metálicas enterradas, revestimiento de túneles y tubos termoplásticos, así como controlar el ancho de las grietas en estructuras de concreto armado, y para análisis transversal relacionado a la tensión en vigas de concreto fabricadas por segmentos. Esta combinación de cargas también se debería utilizar para investigar la estabilidad de los taludes.
- **SERVICIO II** - Combinación de cargas considerado para controlar la fluencia de la estructura de acero y el deslizamiento de las conexiones críticas, debidos a la carga viva vehicular.
- **SERVICIO III** - Combinación de cargas relacionada solamente a la fuerza de tensión en estructuras de concreto pretensado, con el objetivo de controlar las grietas y la tensión principal en el alma de las vigas de concreto fabricadas por segmentos.
- **SERVICIO IV** - Combinación de cargas relacionada exclusivamente a la tensión en las columnas de concreto pretensado con el propósito de controlar las grietas.

La superestructura del puente, se evaluará para los estados límite de Servicio I y II.

- **FATIGA I** - Combinación de carga de fatiga y fractura relacionada a la vida de fatiga infinita por la carga inducida.

El factor de cargas para la combinación de cargas para la Fatiga I, aplicada a un simple camión de diseño que tiene la separación de ejes como se indica en el Artículo 2.4.3.2.4.1 (3.6.1.4.1 AASHTO), que es el camión representativo de una población de camiones que dan un rango de máximos esfuerzos para el diseño de vida de fatiga infinita. El factor fue escogido en la hipótesis que el rango de máximos esfuerzos en el

espectro de variables aleatorias es dos veces el rango de esfuerzo efectivo causado por la combinación de cargas de Fatiga II.

- **FATIGA II** -Combinación de carga de fatiga y fractura relacionada a la vida de fatiga finita por la carga inducida.

El factor de cargas para la combinación de cargas para la Fatiga II, aplicada a un simple camión de diseño, que es el camión representativo de una población de camiones que dan un rango de esfuerzos efectivos con respecto a un pequeño número de rango de esfuerzos cíclicos y a sus efectos acumulativos en elementos de acero, componentes, y conexiones para diseño de vida de fatiga finita. Los factores de carga, para varias cargas que se consideren en una combinación de carga de diseño, serán tomados como los especificados en la Tabla 2.4.5.3.1-1 (3.4.1-1 AASHTO). Los factores de carga para cargas permanentes serán tomados de la Tabla 2.4.5.3.1-2 (3.4.1-2 AASHTO). Los factores serán escogidos para producir el efecto factorizado extremo total. Para cada combinación de carga, serán investigados los máximos valores positivos y máximos valores negativos. En cada combinación de cargas, cada una de las cargas que debe ser considerada y que es relevante para el componente que se está diseñando, incluyendo todas las solicitaciones significativas debidas a la distorsión, se deberán multiplicar por el factor de carga correspondiente y el factor de presencia múltiple especificado en el Artículo 2.4.3.2.2.6 (3.6.1.1.2 AASHTO) si corresponde. Luego los productos se deberán sumar de la manera especificada en la Ecuación 2.3.2.2.1-1 (1.3.2.1-1 AASHTO) y multiplicar por los modificadores de las cargas especificados en el Artículo 2.3.2.2 (1.3.2 AASHTO). En las combinaciones de cargas en las cuales una solicitación reduce otra solicitación, a la carga que reduce la solicitación se le deberá aplicar el valor mínimo. Para las solicitaciones debidas a cargas permanentes, de la Tabla 2.4.5.3.1-2 (3.4.1-2 AASHTO) se deberá seleccionar el factor de carga que produzca la combinación más crítica. Si la carga permanente aumenta la estabilidad o la capacidad de carga de un componente o puente, también se deberá investigar el valor mínimo del factor de carga para dicha carga permanente.

a) Factores de Carga para Cargas Constructivas

Los factores de carga para el peso de la estructura y sus accesorios no se deberán tomar menores que 1.25; para los equipos y para los efectos dinámicos no deberá ser menor que 1.50. El factor de carga para viento no deberá ser menor que 1.25. Todos los demás factores de carga se deberán tomar igual a 1.00.

Los periodos y frecuencias son resumidos en la siguiente tabla:

TABLE Model Participating Mass Ratios																
Output Case	Step Type	Step Num	Period	UX	UY	UZ	SumUX	SumUY	SumUZ	RX	RY	RZ	SumRX	SumRY	SumRZ	
Test	Test	Unitless	Sec	Unitless	Unitless	Unitless	Unitless	Unitless	Unitless	Unitless	Unitless	Unitless	Unitless	Unitless	Unitless	
MODAL	Mode	1	1.500	0.000	0.996	0.000	0.000	0.996	0.000	0.000	0.000	0.000	0.000	0.000	0.000	
MODAL	Mode	2	1.500	1.000	0.000	0.000	1.000	0.996	0.000	0.000	0.000	0.000	0.000	0.000	0.000	
MODAL	Mode	3	0.879	0.000	0.000	0.000	1.000	0.996	0.000	0.000	0.000	1.000	0.000	0.000	1.000	
MODAL	Mode	4	0.500	0.000	0.000	0.792	1.000	0.996	0.792	0.000	0.000	0.000	0.000	0.000	1.000	
MODAL	Mode	5	0.480	0.000	0.000	0.000	1.000	0.999	0.792	0.591	0.000	0.000	0.590	0.000	1.000	
MODAL	Mode	6	0.300	0.000	0.000	0.000	1.000	0.999	0.792	0.238	0.000	0.000	0.831	0.000	1.000	
MODAL	Mode	7	0.224	0.000	0.000	0.000	1.000	0.999	0.792	0.000	0.000	0.000	0.831	0.000	1.000	
MODAL	Mode	8	0.222	0.000	0.000	0.000	1.000	0.999	0.792	0.000	0.155	0.000	0.831	0.155	1.000	
MODAL	Mode	9	0.218	0.000	0.000	0.000	1.000	0.999	0.792	0.000	0.000	0.000	0.831	0.155	1.000	
MODAL	Mode	10	0.218	0.000	0.000	0.001	1.000	0.999	0.793	0.000	0.000	0.000	0.831	0.155	1.000	
MODAL	Mode	11	0.218	0.000	0.000	0.000	1.000	0.999	0.793	0.000	0.005	0.000	0.831	0.160	1.000	
MODAL	Mode	12	0.218	0.000	0.000	0.000	1.000	0.999	0.793	0.000	0.000	0.000	0.831	0.160	1.000	
MODAL	Mode	13	0.217	0.000	0.000	0.000	1.000	0.999	0.793	0.000	0.000	0.000	0.831	0.160	1.000	
MODAL	Mode	14	0.214	0.000	0.000	0.000	1.000	0.999	0.793	0.000	0.000	0.000	0.831	0.160	1.000	
MODAL	Mode	15	0.213	0.000	0.000	0.000	1.000	0.999	0.793	0.000	0.000	0.000	0.831	0.160	1.000	
MODAL	Mode	16	0.213	0.000	0.000	0.000	1.000	0.999	0.793	0.000	0.000	0.000	0.831	0.160	1.000	
MODAL	Mode	17	0.212	0.000	0.000	0.000	1.000	0.999	0.793	0.000	0.000	0.000	0.831	0.160	1.000	
MODAL	Mode	18	0.208	0.000	0.000	0.000	1.000	0.999	0.793	0.000	0.394	0.000	0.831	0.556	1.000	
MODAL	Mode	19	0.195	0.000	0.000	0.000	1.000	0.999	0.793	0.000	0.000	0.000	0.831	0.556	1.000	
MODAL	Mode	20	0.195	0.000	0.000	0.000	1.000	0.999	0.793	0.000	0.003	0.000	0.831	0.560	1.000	
MODAL	Mode	21	0.174	0.000	0.000	0.001	1.000	0.999	0.795	0.000	0.000	0.000	0.831	0.560	1.000	
MODAL	Mode	22	0.174	0.000	0.000	0.000	1.000	0.999	0.795	0.000	0.000	0.000	0.831	0.560	1.000	
MODAL	Mode	23	0.173	0.000	0.001	0.000	1.000	1.000	0.795	0.014	0.000	0.000	0.845	0.560	1.000	
MODAL	Mode	24	0.157	0.000	0.000	0.007	1.000	1.000	0.881	0.000	0.000	0.000	0.845	0.560	1.000	
MODAL	Mode	25	0.139	0.000	0.000	0.000	1.000	1.000	0.881	0.000	0.145	0.000	0.845	0.705	1.000	

MODAL	Mode	24	0.132	0.000	0.000	0.000	1.000	1.000	0.881	0.000	0.000	0.000	0.845	0.705	1.000
MODAL	Mode	27	0.130	0.000	0.000	0.044	1.000	1.000	0.804	0.000	0.000	0.000	0.845	0.705	1.000
MODAL	Mode	28	0.125	0.000	0.000	0.000	1.000	1.000	0.504	0.000	0.107	0.000	0.845	0.812	1.000
MODAL	Mode	29	0.120	0.000	0.000	0.022	1.000	1.000	0.500	0.000	0.000	0.000	0.845	0.812	1.000
MODAL	Mode	30	0.113	0.000	0.000	0.000	1.000	1.000	0.998	0.000	0.031	0.000	0.845	0.893	1.000
MODAL	Mode	31	0.107	0.000	0.000	0.000	1.000	1.000	0.998	0.004	0.000	0.000	0.831	0.893	1.000
MODAL	Mode	32	0.104	0.000	0.000	0.007	1.000	1.000	0.505	0.000	0.000	0.000	0.831	0.893	1.000
MODAL	Mode	33	0.100	0.000	0.000	0.000	1.000	1.000	0.505	0.000	0.011	0.000	0.831	0.894	1.000
MODAL	Mode	34	0.099	0.000	0.000	0.000	1.000	1.000	0.805	0.000	0.007	0.000	0.831	0.890	1.000
MODAL	Mode	35	0.093	0.000	0.000	0.004	1.000	1.000	0.809	0.000	0.000	0.000	0.831	0.890	1.000
MODAL	Mode	34	0.091	0.000	0.000	0.000	1.000	1.000	0.509	0.044	0.000	0.000	0.817	0.890	1.000
MODAL	Mode	37	0.089	0.000	0.000	0.000	1.000	1.000	0.809	0.000	0.000	0.000	0.817	0.890	1.000
MODAL	Mode	38	0.089	0.000	0.000	0.000	1.000	1.000	0.809	0.000	0.000	0.000	0.817	0.891	1.000
MODAL	Mode	39	0.087	0.000	0.000	0.000	1.000	1.000	0.509	0.000	0.000	0.000	0.817	0.891	1.000
MODAL	Mode	40	0.084	0.000	0.000	0.000	1.000	1.000	0.509	0.000	0.007	0.000	0.817	0.890	1.000
MODAL	Mode	41	0.081	0.000	0.000	0.000	1.000	1.000	0.809	0.000	0.000	0.000	0.817	0.890	1.000
MODAL	Mode	42	0.081	0.000	0.000	0.000	1.000	1.000	0.809	0.002	0.000	0.000	0.819	0.890	1.000
MODAL	Mode	43	0.081	0.000	0.000	0.001	1.000	1.000	0.540	0.000	0.000	0.000	0.819	0.890	1.000
MODAL	Mode	44	0.079	0.000	0.000	0.002	1.000	1.000	0.542	0.000	0.000	0.000	0.819	0.890	1.000
MODAL	Mode	45	0.078	0.000	0.000	0.000	1.000	1.000	0.842	0.000	0.000	0.000	0.819	0.890	1.000
MODAL	Mode	44	0.074	0.000	0.000	0.000	1.000	1.000	0.842	0.000	0.000	0.000	0.819	0.890	1.000
MODAL	Mode	47	0.073	0.000	0.000	0.000	1.000	1.000	0.542	0.000	0.005	0.000	0.819	0.872	1.000
MODAL	Mode	48	0.078	0.000	0.000	0.000	1.000	1.000	0.542	0.000	0.000	0.000	0.819	0.872	1.000
MODAL	Mode	49	0.073	0.000	0.000	0.000	1.000	1.000	0.842	0.000	0.000	0.000	0.819	0.872	1.000
MODAL	Mode	50	0.073	0.000	0.000	0.000	1.000	1.000	0.842	0.013	0.000	0.000	0.824	0.872	1.000

4.1.6. DESPLAZAMIENTOS PARA EFECTOS SÍSMICOS

La superestructura del puente, se diseñará para los estados límite de Resistencia I y V.

Las unidades están en “m”.




Figura 4.18: Desplazamiento longitudinal de la parte superior del apoyo. fuente : elaboración propia.




Figura 4.19: Desplazamiento transversal del puente. fuente: elaboración propia.

4.1.7. DEFLEXIONES POR CARGA VIVA

Se considera que la máxima deflexión permitida por carga viva en puentes vehiculares con carga peatonal es de $L/1000$. La deflexión será tomada como el mayor valor del resultado que se obtiene del camión de diseño solo o el resultado de tomar el 25 % del camión de diseño junto con la carga repartida de diseño (3.6.1.3.2 AASHTO).

max longitudinalmente= $70/1000=0.0700\text{m}$.

max transversalmente= $11.60/1000=0.01160\text{m}$.

Las unidades están en “m”.




Figura 4.20: Deflexión longitudinal del puente de 0.0222m. fuente: elaboración propia




Figura 4.21: Deflexión transversal de 0.0222-0.015=0.0072m. fuente: elaboración propia.

Como se puede observar en los dos casos las deflexiones son menores que el admisible.

4.1.8. IDENTIFICACION DE SECCIONES Y ETIQUETAS DEL MODELO

- En el modelo se asignaron las siguientes secciones:




Figura 4.22: Identificación de secciones en el modelo. fuente: elaboración propia.

- En el modelo se asignaron las siguientes etiquetas:




Figura 4.23: Identificación de secciones en el modelo. fuente: elaboración propia.

4.1.9. DIAGRAMA DE FUERZAS

DIAGRAMA DE FUERZAS AXIALES




Figura 4.24: Diagrama de Fuerzas Axiales debido a DC (Tonf). fuente: elaboración propia.




Figura 4.25: Diagrama de Fuerzas Axiales debido a DW (Tonf). fuente: elaboración propia.




Figura 4.26: Diagrama de Fuerzas Axiales debido a LL+IM (Tonf). fuente: elaboración propia.




Figura 4.27: Diagrama de Fuerzas Axiales debido a PL (Tonf). fuente: elaboración propia.




Figura 4.28: Diagrama de Fuerzas Axiales debido a WS (Tonf). fuente: elaboración propia..




Figura 4.29: Diagrama de Fuerzas Axiales debido a TU pos (Tonf). fuente: elaboración propia.




Figura 4.30: Diagrama de Fuerzas Axiales debido a Tu neg (Tonf). fuente: elaboración propia.

DIAGRAMA DE MOMENTOS FLECTORES




Figura 4.31: Diagrama de Momento Flector debido a DC (Tonf-m). fuente: elaboración propia.




Figura 4.32: Diagrama de Momento Flector debido a DW (Tonf-m). fuente: elaboración propia.




Figura 4.33: Diagrama de Momento Flector debido a LL+IM (Tonf-m). fuente: elaboración propia.




Figura 4.34: Diagrama de Momento Flector debido a PL (Tonf-m). fuente: elaboración propia.




Figura 4.35: Diagrama de Momento Flector debido a WS (Tonf-m). fuente: elaboración propia.




Figura 4.36: Diagrama de Momento Flector debido a TU pos (Tonf-m). fuente: elaboración propia.





Figura 4.37: Diagrama de Momento Flector debido a T_u neg (Tonf-m). fuente: elaboración propia.

4.1.10. DISEÑO DE ELEMENTOS METÁLICOS

El cálculo de los elementos del puente se realizó suponiendo diversas etapas constructivas consistentes con las etapas propuestas para la construcción del puente, las cuales son indicadas a continuación:

El proceso constructivo propuesto para la construcción de la estructura es el siguiente:

- Construcción de subestructura: Estribos
- Se realiza el montaje de la estructura metálica y el armado de la misma.
- Se realiza el vaciado de la losa.
- Se procede a la colocación de vereda, barandas y asfalto.
- Se deja transcurrir el tiempo para generar los efectos de Creep y Shrinkage.



A. BRIDA INFERIOR (BI-01)

AASHTO LRFD 2007 STEEL SECTION CHECK

Combo : RESISTENCIA I-a

Units : Tonf, m, C

Frame : 244 Design Sect: BI01-002
X Mid : 22.5 Design Type: Beam
Y Mid : -5.8 Frame Type : Braced Frame
Z Mid : -0.187 Sect Class : Plastic
Length : 5. Major Axis : 0. degrees counterclockwise from local 3
Loc : 5. RLLF : 1.

Area : 0.037 SMajor : 0.007 rMajor : 0.238 AMMajor: 0.015
IMajor : 0.002 SMinor : 0.001 rMinor : 0.075 AMMinor: 0.02
IMinor : 2.082E-04 ZMajor : 0.008 E : 20389019.168
Ixy : 0. ZMinor : 0.002 Fy : 35153.481

STRESS CHECK FORCES & MOMENTS

Location	Pu	Mu33	Mu22	Vu2	Vu3	Tu
5.	660.468	26.25	7.077	-0.743	-1.523	0.09

RFI DEMAND/CAPACITY RATIO

Governing Equation	Total Ratio	P Ratio	MMajor Ratio	MMinor Ratio	Ratio Limit	Status Check
(6.9.2.3-2)	0.706	= 0.534	+ 0.08	+ 0.092	1.	OK

AXIAL FORCE DESIGN

	Pu Force	phi*Pnc Capacity	phi*Pnt Capacity
Axial	660.468	976.077	1237.148

MOMENT DESIGN

	Mu Moment	phi*Mn Capacity	Cm Factor	Db Factor	Ds Factor	K Factor	L Factor	Cb Factor
Major Moment	26.25	290.747	1.	1.	1.	0.75	1.	1.389
Minor Moment	7.077	68.618	1.	1.	1.	0.75	1.	

SHEAR DESIGN

	Vu Force	phi*Vn Capacity	Stress Ratio	Status Check	Tu Torsion
Major Shear	3.739	259.45	0.014	OK	0.
Minor Shear	2.96	495.861	0.006	OK	0.

B. BRIDA SUPERIOR (BS-01)

AASHTO LRFD 2007 STEEL SECTION CHECK

Combo : RESISTENCIA I -b
Units : Tonf, m, C

Frame : 310 Design Sect: PI-23
X Mid : 17.5 Design Type: Beam
Y Mid : 5.8 Frame Type : Braced Frame
Z Mid : 7.233 Sect Class : Non-Compact
Length : 5. Major Axis : 0. degrees counterclockwise from local 3
Loc : 0. RLLF : 1.

Area : 0.048 SMajor : 0.003 xMajor : 0.143 AVMajor: 0.026
IMajor : 9.817E-04 SMinor : 0.006 xMinor : 0.184 AVMinor: 0.019
IMinor : 0.002 ZMajor : 0.006 E : 20889019.159
Ixy : 0. ZMinor : 0.008 Fy : 35153.481

STRESS CHECK FORCES & MOMENTS

Location	Pu	Mu33	Mu22	Vu2	Vu3	Tu
0.	-780.809	-21.567	-13.476	-6.845	-5.737	-0.258

PBDF DEMAND/CAPACITY RATIO

Governing Equation	Total Ratio	P Ratio	SMajor Ratio	SMinor Ratio	Ratio Limit	Status Check
(6.9.2.2-2)	0.955	= 0.626	+ 0.266	+ 0.063	1.	OK

AXIAL FORCE DESIGN

	Pu Force	phi*Pnc Capacity	phi*Pnt Capacity
Axial	-780.809	1248.048	1612.817

MOMENT DESIGN

	Mu Moment	phi*Mn Capacity	Cm Factor	Db Factor	Ds Factor	K Factor	L Factor	Cb Factor
Major Moment	-33.525	111.987	1.	1.654	1.	0.75	2.	2.167
Minor Moment	-14.136	159.721	1.	1.063	1.	0.75	1.	

SHEAR DESIGN

	Vu Force	phi*Vn Capacity	Stress Ratio	Status Check	Tu Torsion
Major Shear	6.845	520.257	0.013	OK	0.
Minor Shear	5.737	359.743	0.016	OK	0.

C. DIAGONALES (D-01)

AASHTO LRFD 2007 STEEL SECTION CHECK

Combo : RESISTENCIA I -b

Units : Tonf, m, C

Frame : 276 Design Sect: D01
 X Mid : 2.5 Design Type: Brace
 Y Mid : 5.8 Frame Type : Braced Frame
 Z Mid : 3.523 Sect Class : Non-Compact
 Length : 8.947 Major Axis : 0. degrees counterclockwise from local 3
 Loc : 8.947 RLLF : 1.

Area : 0.026 SMajor : 0.003 xMajor : 0.135 AMMajor: 0.014
 IMajor : 4.809E-04 SMinor : 0.003 xMinor : 0.135 AMMinor: 0.014
 IMinor : 4.809E-04 ZMajor : 0.003 E : 20389019.158
 Ixy : 0. ZMinor : 0.003 Fy : 32341.203

STRESS CHECK FORCES & MOMENTS

Location	Pu	Mu33	Mu22	Vu2	Vu3	Tu
8.947	-465.135	12.34	-8.269	-0.843	1.442	-5.716

FR1 DEMAND/CAPACITY RATIO

Governing Equation	Total Ratio	P Ratio	MMajor Ratio	MMinor Ratio	Ratio Limit	Status Check
(6.9.2.2-2)	0.929	= 0.715	+ 0.128	+ 0.086	1.	OK

AXIAL FORCE DESIGN

	Pu Force	phi*Pnc Capacity	phi*Pnt Capacity
Axial	-465.135	650.707	811.117

MOMENT DESIGN

	Mu Moment	phi*Mn Capacity	Cm Factor	Db Factor	Ds Factor	K Factor	L Factor	Cb Factor
Major Moment	12.34	85.671	1.	1.	1.	0.75	1.	1.497
Minor Moment	-8.269	85.671	1.	1.	1.	0.75	1.	

SHEAR DESIGN

	Vu Force	phi*Vn Capacity	Stress Ratio	Status Check	Tu Torsion
Major Shear	0.843	232.598	0.004	OK	0.
Minor Shear	1.889	116.299	0.016	OK	0.

D. DIAGONALES (D-01)

```

AASHTO LRFD 2007 STEEL SECTION CHECK
Combo : RESISTENCIA I -b
Units : Tonf, m, C

Frame : 280          Design Sect: D02
X Mid : 17.5         Design Type: Brace
Y Mid : 5.0          Frame Type : Braced Frame
Z Mid : 3.523        Sect Class : Non-Compact
Length : 8.947        Major Axis : 0. degrees counterclockwise from local 3
Loc : 0.             RLLF : 1.

Area : 0.015         SMajor : 0.001          rMajor : 0.117          AVMajor: 0.004
IMajor : 2.053E-04   SMinor : 0.001          rMinor : 0.117          AVMinor: 0.004
IMinor : 2.053E-04   ZMajor : 0.002          E : 20389019.158
IXY : 0.             ZMinor : 0.002          Fy : 32341.203

STRESS CHECK FORCES & MOMENTS
Location      Pu      Mu33      Mu22      Vu2      Vu3      Tu
0.            259.695  -1.469    14.955    -0.316    0.941    1.495

PDS1 DEMAND/CAPACITY RATIO
Governing      Total      P      M2Major      M2Minor      Ratio      Status
Equation      Ratio      Ratio      Ratio      Ratio      Limit      Check
(6.9.2.3-2)    0.916    = 0.566    + 0.031    + 0.318    1.        OK

AXIAL FORCE DESIGN
Pu      phi*Pnc      phi*Pnt
Force   Capacity  Capacity
Axial   259.695    293.677    458.527

MOMENT DESIGN
Mu      phi*Mn      Cm      Db      Ds      K      L      Cb
Moment  Capacity  Factor  Factor  Factor  Factor  Factor  Factor
Major Moment -1.469    41.792    1.      1.      1.      1.      1.      1.676
Minor Moment 14.955    41.792    1.      1.      1.      1.      1.      1.

SHEAR DESIGN
Vu      phi*Vn      Stress      Status      Tu
Force   Capacity  Ratio      Check      Torsion
Major Shear 0.487    133.631    0.004      OK      0.
Minor Shear 2.242    66.816     0.034      OK      0.

```

E. MONTANTES (M-01)


```

AASHTO LRFD 2007 STEEL SECTION CHECK
Combo : RESISTENCIA I -b
Units : Tonf, m, C

Frame : 343          Design Sect: M01
X Mid : 15.          Design Type: Column
Y Mid : 5.8          Frame Type : Braced Frame
Z Mid : 3.823        Sect Class : Plastic
Length : 7.42        Major Axis : 0. degrees counterclockwise from local 3
Loc : 7.42           RLLF : 1.

Area : 0.024          SMajor : 0.003          xMajor : 0.159          AVMajor: 0.006
IMajor : 5.951E-04    SMinor : 0.001          xMinor : 0.095          AVMinor: 0.015
IMinor : 2.112E-04    ZMajor : 0.004          E : 20389019.158
Ixy : 0.              ZMinor : 0.002          Fy : 35153.481

STRESS CHECK FORCES & MOMENTS
Location      Pu      Mu33      Mu32      Vu3      Vu3      Tu
7.42          84.008   -43.621   3.599     6.896    -0.691   -0.005

FORM DEMAND/CAPACITY RATIO
Governing      Total      P      SMajor      SMinor      Ratio      Status
Equation        Ratio      Ratio      Ratio      Ratio      Limit      Check
(6.9.2.3-1)    0.458    = 0.053    + 0.345    + 0.06      1.        OK

AXIAL FORCE DESIGN
              Pu      phi*Pnc      phi*Pnt
Force         Capacity Capacity
Axial         84.008   415.434     788.809

MOMENT DESIGN
              Mu      phi*Mn      Cm      Db      Ds      K      L      Cb
Moment        Capacity Factor Factor Factor Factor Factor Factor
Major Moment  -43.621   126.682     1.      1.      1.      1.917   1.      1.798
Minor Moment   3.599    60.188     1.      1.      1.      1.03    1.

SHEAR DESIGN
              Vu      phi*Vn      Stress      Status      Tu
Force         Capacity Ratio      Check      Torsion
Major Shear    6.896    104.392     0.066      OK          0.
Minor Shear    0.691    377.197     0.002      OK          0.

```

F. ARRIOSTRES INFERIORES (AI-01)

AASHTO LRFD 2007 STEEL SECTION CHECK

Combo : RESISTENCIA I -c

Units : Tonf, m, C

Frame : 400 Design Sect: AI01
 X Mid : 12.5 Design Type: Beam
 Y Mid : 2.9 Frame Type : Braced Frame
 Z Mid : -0.437 Sect Class : Plastic
 Length : 7.658 Major Axis : 0. degrees counterclockwise from Local 3
 Loc : 3.829 RLLF : 1.

Area : 0.006 SMajor : 5.257E-04 xMajor : 0.114 AVMajor: 0.002
 IMajor : 7.284E-05 SMinor : 5.014E-05 xMinor : 0.035 AVMinor: 0.003
 IMinor : 6.761E-06 SMajor : 5.994E-04 E : 20389019.159
 Ixy : 0. ZMinor : 1.350E-04 Fy : 35153.461

STRESS CHECK FORCES & MOMENTS

Location	Pu	Mu33	Mu22	Vu2	Vu3	Tu
3.829	91.232	0.51	0.	0.	0.	-3.367E-04

PER DEMAND/CAPACITY RATIO

Governing Equation	Total Ratio	P Ratio	SMajor Ratio	SMinor Ratio	Ratio Limit	Status Check
(6.9.2.3-2)	0.556	= 0.487	+ 0.069	+ 0.	1.	OK

AXIAL FORCE DESIGN

	Pu Force	phi*Pnc Capacity	phi*Pnt Capacity
Axial	91.232	18.312	187.284

MOMENT DESIGN

	Mu Moment	phi*Mn Capacity	Cm Factor	Db Factor	Ds Factor	K Factor	L Factor	Cb Factor
Major Moment	0.51	6.606	1.	1.	1.	1.	1.	1.
Minor Moment	0.	4.753	1.	1.	1.	1.	1.	1.

SHEAR DESIGN

	Vu Force	phi*Vn Capacity	Stress Ratio	Status Check	Tu Torsion
Major Shear	3.429E-17	40.941	0.	OK	0.
Minor Shear	0.	73.4	0.	OK	0.

G. ARRIOSTRES SUPERIORES (AS-01)

```

AASHTO LRFD 2007 STEEL SECTION CHECK
Combo : RESISTENCIA IIIa
Units : Tonf, m, C

Frame : 352          Design Sect: AS01
X Mid : 8.          Design Type: Beam
Y Mid : 0.          Frame Type : Braced Frame
Z Mid : 7.233       Sect Class : Plastic
Length : 11.6       Major Axis : 0. degrees counterclockwise from local 3
Loc : 11.6          RLLF : 1.

Area : 0.005         SMajor : 3.988E-04      xMajor : 0.087      AUMajor: 0.002
IMajor : 4.088E-05   SMinor : 1.090E-04      xMinor : 0.041      AUMinor: 0.003
IMinor : 8.992E-06   ZMajor : 4.477E-04      E : 20385019.158
Ixy : 0.             ZMinor : 1.662E-04      Fy : 35153.481

STRESS CHECK FORCES & MOMENTS
Location      Pu      Mu33      Mu22      Vu2      Vu3      Tu
11.6          -10.367  -5.778   -0.079    1.353    0.018    1.018E-04

PSM DEMAND/CAPACITY RATIO
Governing      Total      P      MMajor      MMinor      Ratio      Status
Equation        Ratio      Ratio      Ratio      Ratio      Limit      Check
(6.9.2.2-2)    0.602    = 0.244  + 0.345  + 0.013    1.        OK

AXIAL FORCE DESIGN
          Pu      phi*Pnc      phi*Pnt
Force      Capacity      Capacity
Axial      -10.367    42.456    180.605

MOMENT DESIGN
          Mu      phi*Mn      Cm      Db      Ds      K      L      Cb
Moment      Capacity      Factor      Factor      Factor      Factor      Factor      Factor
Major Moment -6.108    15.737    1.    1.204    1.    1.    1.    2.3
Minor Moment -0.085     5.747    1.    1.235    1.    1.    0.5

SHEAR DESIGN
          Vu      phi*Vn      Stress      Status      Tu
Force      Capacity      Ratio      Check      Torsion
Major Shear  1.353    29.523    0.046    OK      0.
Minor Shear  0.018    80.741     0.        OK      0.

```

4.1.11. Desarrollo e implementación de modelo DNN y PSO aplicado a la optimización Topológica del puente.

METODOLOGÍA

El objetivo de este trabajo es desarrollar una herramienta computacional que apoye el diseño preliminar de puentes reticulados, combinando aprendizaje automático y algoritmos de optimización bioinspirada. La metodología consiste en entrenar una red neuronal profunda capaz de estimar el peso estructural del puente a partir de variables geométricas, y utilizar dicho modelo como función objetivo dentro de un algoritmo PSO.

El sistema permite que el usuario defina ciertas características topológicas del puente, mientras que las variables geométricas continuas son optimizadas automáticamente mediante PSO, mientras que las variables restantes son optimizadas automáticamente para minimizar el peso estimado.

IMPORTACIÓN DE LIBRERIAS

```

1 import pandas as pd
2 import numpy as np
3 from sklearn.preprocessing import StandardScaler, LabelEncoder
4 from sklearn.model_selection import train_test_split
5 from sklearn.preprocessing import StandardScaler
6 from sklearn.neural_network import MLPRegressor
7 from sklearn.metrics import r2_score, mean_absolute_error
8 import matplotlib.pyplot as plt
9 import tensorflow as tf
10 from tensorflow.keras.models import Sequential
11 from tensorflow.keras.layers import Dense, Dropout
12 from tensorflow.keras.callbacks import EarlyStopping

```

IMPLEMENTACIÓN

Preprocesamiento de datos

El conjunto de datos utilizado contiene información geométrica y topológica de diferentes configuraciones de puentes reticulados. Antes del entrenamiento del modelo, se realizó un proceso de limpieza y selección de variables, eliminando características no numéricas y aquellas que no aportan información relevante al modelo.

Posteriormente, los datos fueron normalizados con el objetivo de mejorar la estabilidad del entrenamiento de la red neuronal y asegurar que todas las variables tengan una influencia comparable.

Arquitectura del sistema

El sistema se compone de tres módulos principales: procesamiento de datos, modelo de red neuronal y módulo de optimización. El modelo de red neuronal actúa como un modelo sustituto que estima el peso estructural del puente, mientras que el algoritmo PSO explora distintas configuraciones geométricas hasta encontrar el diseño que minimiza dicho peso.

Importar dataframe, variables de entrada y codificación de variables categóricas

```
1 df = pd.read_csv("drive/MyDrive/Trabajo PSO/DATAPUENTE.csv", sep=";", encoding="latin1")
2
3 #Limpieza
4 df.columns = df.columns.str.strip()
5 df = df.dropna()
6
7 df.head()
8
```

	Longitud (m)	Ancho de Puente (m)	Sep Vigas Longitudinales (m)	Nº Paneles	Altura (m)	Disposicion de Arriostre	Forma de Arriostre	Dia. Arriostre	Forma de Cordones	Dimension de Cordon Sup/Inf	Forma de Diagonales	Dia. Diag. S/I	Forma de Montante	Dia. Montante	Peso total (ton)
0	55	11.6	2.1	6	5.5	Cruz	T	150x150x12.5	Cajon HSS	400x410x19.0	Cajon HSS	380x390x16.0	Cajon HSS	200x200x12.5	119.00
1	55	11.6	2.1	6	5.5	Cruz	L	150x150x12.5	Cajon HSS	410x420x19.0	Cajon HSS	390x400x16.0	Cajon HSS	200x200x12.5	122.18
2	55	11.6	2.1	6	5.6	Cruz	T	150x150x12.5	Cajon HSS	420x430x19.0	Cajon HSS	400x410x16.0	Cajon HSS	200x200x12.5	125.46
3	55	11.6	2.1	6	5.6	Cruz	L	150x150x12.5	Cajon HSS	430x400x19.0	Cajon HSS	410x380x16.0	Cajon HSS	200x200x12.5	122.27
4	55	11.6	2.1	6	5.7	Cruz	T	150x150x12.5	Cajon HSS	400x410x19.0	Cajon HSS	380x390x16.0	Cajon HSS	200x200x12.5	119.17

```
1 features = [
2     'Longitud (m)',
3     'Ancho de Puente (m)',
4     'Altura (m)',
5     'Nº Paneles',
6     'Sep Vigas Longitudinales (m)',
7     'Disposicion de Arriostre',
8     'Forma de Arriostre',
9     'Forma de Cordones',
10    'Forma de Diagonales',
11    'Forma de Montante'
12 ]
13
14 target = 'Peso total (ton)'
15
16 encoders = {}
17 for col in features:
18     if df[col].dtype == 'object':
19         le = LabelEncoder()
20         df[col] = le.fit_transform(df[col])
21         encoders[col] = le
```

Modelo de red neuronal profunda

La red neuronal se entrena con el objetivo de aprender la relación entre la geometría del puente y su peso total. Una vez entrenada, la red se utiliza como modelo predictivo dentro del proceso de optimización.

```

1  X = df[features].values
2  y = df[target].values.reshape(-1, 1)
3
4  scaler_X = StandardScaler()
5  scaler_y = StandardScaler()
6
7  X_scaled = scaler_X.fit_transform(X)
8  y_scaled = scaler_y.fit_transform(y)
9
10 from sklearn.model_selection import train_test_split
11
12 X_train, X_test, y_train, y_test = train_test_split(
13     X_scaled, y_scaled, test_size=0.2, random_state=42
14 )
15
16 model = Sequential([
17     Dense(128, activation='relu', input_shape=(X_train.shape[1],)),
18     Dropout(0.2),
19
20     Dense(64, activation='relu'),
21     Dropout(0.2),
22
23     Dense(32, activation='relu'),
24
25     Dense(1, activation='linear')
26 ])
27
28 model.compile(
29     optimizer=tf.keras.optimizers.Adam(learning_rate=0.001),
30     loss='mse'
31 )
32
33 model.summary()

```

/usr/local/lib/python3.12/dist-packages/keras/src/layers/core/dense.py:93: User
super().__init__(activity_regularizer=activity_regularizer, **kwargs)
Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 128)	1,408
dropout (Dropout)	(None, 128)	0
dense_1 (Dense)	(None, 64)	8,256
dropout_1 (Dropout)	(None, 64)	0
dense_2 (Dense)	(None, 32)	2,080
dense_3 (Dense)	(None, 1)	33

Total params: 11,777 (46.00 KB)
Trainable params: 11,777 (46.00 KB)
Non-trainable params: 0 (0.00 B)

Entrenamiento controlado

```
1 early_stop = EarlyStopping(  
2     monitor='val_loss',  
3     patience=30,  
4     restore_best_weights=True  
5 )  
6  
7 history = model.fit(  
8     X_train, y_train,  
9     validation_split=0.2,  
10    epochs=500,  
11    batch_size=16,  
12    callbacks=[early_stop],  
13    verbose=1  
14 )
```

Epoch 13/500
41/41 ————— 0s 4ms/step - loss: 0.0232 - val_loss: 0.0169
Epoch 14/500
41/41 ————— 0s 4ms/step - loss: 0.0283 - val_loss: 0.0149
Epoch 15/500
41/41 ————— 0s 3ms/step - loss: 0.0232 - val_loss: 0.0149
Epoch 16/500
41/41 ————— 0s 3ms/step - loss: 0.0253 - val_loss: 0.0097
Epoch 17/500
41/41 ————— 0s 4ms/step - loss: 0.0269 - val_loss: 0.0143
Epoch 18/500

Evaluación del modelo

El desempeño del modelo entrenado se evaluó mediante métricas estadísticas como el coeficiente de determinación (R^2) y el error absoluto medio (MAE). Estas métricas permiten cuantificar la precisión del modelo y analizar su comportamiento tanto en el conjunto de entrenamiento como en el conjunto de prueba.

Además, se presentan gráficas que comparan los valores reales y los valores estimados del peso estructural.

```
1 y_train_pred = scaler_y.inverse_transform(model.predict(X_train))  
2 y_test_pred = scaler_y.inverse_transform(model.predict(X_test))  
3  
4 y_train_real = scaler_y.inverse_transform(y_train)  
5 y_test_real = scaler_y.inverse_transform(y_test)  
6  
7 print("R² entrenamiento:", r2_score(y_train_real, y_train_pred))  
8 print("R² test:", r2_score(y_test_real, y_test_pred))  
9  
10 print("MAE test (ton):", mean_absolute_error(y_test_real, y_test_pred))  
11
```

26/26 ————— 0s 3ms/step
7/7 ————— 0s 4ms/step
R² entrenamiento: 0.9925144464457998
R² test: 0.9928886138033689
MAE test (ton): 8.564511031728658


```
1 mae = mean_absolute_error(y_test_real, y_test_pred)  
2 peso_promedio = df["Peso total (ton)"].mean()  
3  
4 error_relativo = (mae / peso_promedio) * 100  
5  
6 print(f"Peso promedio del conjunto: {peso_promedio:.2f} ton")  
7 print(f"MAE del modelo: {mae:.2f} ton")  
8 print(f"Error relativo promedio: {error_relativo:.2f} %")
```

Peso promedio del conjunto: 310.77 ton
MAE del modelo: 8.56 ton
Error relativo promedio: 2.76 %

El error absoluto medio obtenido representa aproximadamente el 2.6% del peso estructural promedio de los puentes analizados, lo cual resulta aceptable para procesos de optimización preliminar y toma de decisiones en etapas tempranas de diseño.


Gráfica de entrenamiento de la DNN

```
1 plt.figure(figsize=(8,5))
2 plt.plot(history.history['loss'], label='Entrenamiento')
3 plt.plot(history.history['val_loss'], label='Validación')
4
5 plt.xlabel('Épocas')
6 plt.ylabel('MSE (pérdida)')
7 plt.title('Curva de entrenamiento de la DNN')
8 plt.legend()
9 plt.grid(True)
10 plt.show()
```



La figura muestra la evolución de la función de pérdida durante el entrenamiento del modelo de red neuronal. Se observa una convergencia estable tanto en el conjunto de entrenamiento como de validación, sin evidencias de sobreajuste, lo que confirma la capacidad de generalización del modelo.

```
1 plt.figure(figsize=(6,6))
2 plt.scatter(y_test_real, y_test_pred, alpha=0.6)
3 plt.plot(
4     [y_test_real.min(), y_test_real.max()],
5     [y_test_real.min(), y_test_real.max()],
6     linestyle="--"
7 )
8 plt.xlabel("Peso real (ton)")
9 plt.ylabel("Peso estimado por la DNN (ton)")
10 plt.title("Comparación peso real vs peso estimado")
11 plt.grid(True)
12 plt.show()
13
```



PSO

Optimización asistida por el usuario

En esta etapa, el usuario define ciertas variables geométricas del puente, las cuales actúan como restricciones iniciales. A partir de estas condiciones, el algoritmo PSO optimiza automáticamente las variables restantes con el objetivo de minimizar el peso estructural estimado por la red neuronal.

```
1 # --- CONFIGURACIÓN DEL USUARIO ---
2 '''
3 user_inputs = {
4     "Disposición de Arriostre": "Cruz",
5     "Forma de Arriostre": "T",
6     "Forma de Cordones": "Cajon HSS",
7     "Forma de Diagonales": "Cajon HSS",
8     "Forma de Montante": "Cajon HSS",
9     "Longitud (m)": 58 # nueva variable fija
10 }'''
11
12 # --- CONFIGURACIÓN DEL USUARIO MANUAL ---
13
14 # Variables categóricas
15 user_inputs = {}
16
17 user_inputs["Disposición de Arriostre"] = input("Ingrese Disposición de Arriostre (ej. Cruz, Paralela): ")
18 user_inputs["Forma de Arriostre"] = input("Ingrese Forma de Arriostre (ej. T, L): ")
19 user_inputs["Forma de Cordones"] = input("Ingrese Forma de Cordones (ej. Cajon HSS): ")
20 user_inputs["Forma de Diagonales"] = input("Ingrese Forma de Diagonales (ej. Cajon HSS): ")
21 user_inputs["Forma de Montante"] = input("Ingrese Forma de Montante (ej. Cajon HSS): ")
22
23 user_inputs["Longitud (m)"] = float(input("Ingrese Longitud del puente en metros (ej. 58): "))
24
```

Ingrese Disposición de Arriostre (ej. Cruz, Paralela): Cruz
 Ingrese Forma de Arriostre (ej. T, L): T
 Ingrese Forma de Cordones (ej. Cajon HSS): Cajon HSS
 Ingrese Forma de Diagonales (ej. Cajon HSS): Cajon HSS

Definir variables de diseño

```
1  # Variables totales usadas por la DNN
2  all_features = features
3
4  # Variables que PSO va a optimizar
5  pso_features = [
6      "Altura (m)",
7      "Nº Paneles",
8      "Ancho de Puente (m)",
9      "Sep Vigas Longitudinales (m)"
10 ]
11
12 # Variables categóricas
13 categorical_features = [
14     "Disposicion de Arriostre",
15     "Forma de Arriostre",
16     "Forma de Cordones",
17     "Forma de Diagonales",
18     "Forma de Montante"
19 ]
20
21 fixed_values = {}
22
23 for col, val in user_inputs.items():
24     if col in categorical_features:
25         fixed_values[col] = encoders[col].transform([val])[0]
26     else:
27         fixed_values[col] = val # valor numérico directamente
28
```

Limites de diseño

```
1  bounds = np.array([
2      (df[f].min(), df[f].max()) for f in pso_features
3  ])
```

Función objetivo

```
1 peso_min_real = df["Peso total (ton)"].min()
2 peso_max_real = df["Peso total (ton)"].max()
3
4 def objective_function(x):
5     full_x = []
6
7     for f in all_features:
8         if f in pso_features:
9             full_x.append(x[pso_features.index(f)])
10        else:
11            full_x.append(fixed_values[f])
12
13    full_x = np.array(full_x).reshape(1, -1)
14    full_x_scaled = scaler_x.transform(full_x)
15
16    y_scaled = model.predict(full_x_scaled, verbose=0)
17    y = scaler_y.inverse_transform(y_scaled)[0, 0]
18
19    # Penalización por extrapolación
20    if y < peso_min_real or y > peso_max_real:
21        return peso_max_real + 100 # castigo fuerte
22
23    return y
24
25
```

Implementación del PSO

Los **parametros del PSO** son los siguientes:

- `n_particles = 30`
- `n_iterations = 80`
- `w = 0.7` # inercia
- `c1 = 1.5` # cognitivo
- `c2 = 1.5` # social

```
1 n_particles = 30
2 n_iterations = 10
3
4 w = 0.9
5 c1 = 2.0
6 c2 = 2.0
```

Inicialización

```
1 dim = len(bounds)
2
3 X = df[psf_features].sample(n_particles).values
4 V = np.zeros_like(X)
5
6 pbest = X.copy()
7 pbest_val = np.array([objective_function(x) for x in X])
8
9 gbest = pbest[np.argmin(pbest_val)]
10 gbest_val = np.min(pbest_val)
11
12 history = []
13 mean_history = []
14 std_history = []
15
```

Bucle principal PSO y Resultados de la optimización

Se presentan los resultados obtenidos a partir del proceso de optimización mediante PSO, incluyendo la evolución del peso estimado a lo largo de las iteraciones. Asimismo, se compara el peso óptimo encontrado con el peso promedio del conjunto de datos, con el fin de evaluar el nivel de mejora alcanzado.

```

1  for it in range(n_iterations):
2
3      for i in range(n_particles):
4          r1, r2 = np.random.rand(), np.random.rand()
5
6          V[i] = (
7              w * V[i]
8              + c1 * r1 * (pbest[i] - X[i])
9              + c2 * r2 * (gbest - X[i])
10         )
11
12         X[i] = X[i] + V[i]
13         X[i] = np.clip(X[i], bounds[:,0], bounds[:,1])
14
15         fitness = objective_function(X[i])
16
17         if fitness < pbest_val[i]:
18             pbest[i] = X[i].copy()
19             pbest_val[i] = fitness
20
21     gbest = pbest[np.argmin(pbest_val)]
22     gbest_val = np.min(pbest_val)
23
24     mean_history.append(np.mean(pbest_val))
25     std_history.append(np.std(pbest_val))
26     history.append(gbest_val)
27
28     print(f"Iteración {it} → Peso óptimo: {gbest_val:.2f} ton")
29

```

```

Iteración 0 → Peso óptimo: 139.06 ton
Iteración 1 → Peso óptimo: 139.06 ton
Iteración 2 → Peso óptimo: 139.06 ton
Iteración 3 → Peso óptimo: 139.06 ton
Iteración 4 → Peso óptimo: 139.06 ton
Iteración 5 → Peso óptimo: 139.06 ton
Iteración 6 → Peso óptimo: 139.06 ton
Iteración 7 → Peso óptimo: 139.06 ton
Iteración 8 → Peso óptimo: 139.06 ton
Iteración 9 → Peso óptimo: 139.06 ton

```

```

1 print("Peso mínimo en el dataset:", df["Peso total (ton)"].min())
2 print("Peso promedio:", df["Peso total (ton)"].mean())
3 print("Peso óptimo PSO:", gbest_val)

```

```

Peso mínimo en el dataset: 119.0
Peso promedio: 310.7655138339921
Peso óptimo PSO: 139.06493

```


Cabe destacar que el peso mínimo obtenido mediante el algoritmo PSO no coincide necesariamente con el valor mínimo presente en el conjunto de datos original, dado que el proceso de optimización se realizó sobre un subconjunto de variables, manteniendo las restantes fijas en valores promedio. En este sentido, el resultado del PSO representa un diseño óptimo condicionado, coherente con las restricciones impuestas y con el dominio de aprendizaje del modelo de red neuronal.

Gráfica de convergencia PSO

```

1 plt.figure(figsize=(8,5))
2 plt.plot(history, label="Mejor global")
3 plt.plot(mean_history, label="Promedio de partículas")
4 plt.fill_between(
5     range(len(history)),
6     np.array(mean_history) - np.array(std_history),
7     np.array(mean_history) + np.array(std_history),
8     alpha=0.3
9 )
10 plt.xlabel("Iteraciones")
11 plt.ylabel("Peso estimado (ton)")
12 plt.title("Evolución del PSO")
13 plt.legend()
14 plt.grid(True)
15 plt.show()
16

```



La curva de convergencia del algoritmo PSO presenta una rápida estabilización del valor óptimo del peso. Este comportamiento se debe a que el proceso de optimización se realizó sobre un número reducido de variables geométricas, manteniendo fijas las características topológicas y de sección. Asimismo, el modelo de red neuronal utilizado como función objetivo presenta una respuesta suave, propia de modelos de interpolación entrenados sobre datos reales, lo cual limita la variación abrupta del peso estimado.

En consecuencia, el algoritmo alcanza rápidamente un óptimo estable dentro de la búsqueda definida.

COMPARACIÓN antes vs después PSO

- **Peso promedio**

```
1 peso_promedio = df["Peso total (ton)"].mean()
2 print(f"Peso promedio del dataset: {peso_promedio:.2f} ton")
```

Peso promedio del dataset: 310.77 ton

- **Peso óptimo encontrado por PSO**

```
1 print(f"Peso óptimo PSO: {gbest_val:.2f} ton")
```

Peso óptimo PSO: 139.06 ton


- **Reducción porcentual**

```
1 reduccion = (peso_promedio - gbest_val) / peso_promedio * 100
2
3 print(f"Reducción de peso lograda: {abs(reduccion):.2f} %")
```

Reducción de peso lograda: 55.25 %

Mediante la aplicación del algoritmo PSO se obtuvo una configuración de diseño que presenta una reducción del peso estructural estimado del orden del 55.25% en comparación con el peso promedio del conjunto de datos analizado. Este resultado se debe a que el proceso de optimización explora combinaciones geométricas que no necesariamente coinciden con los diseños más frecuentes del conjunto original, permitiendo identificar alternativas más eficientes desde el punto de vista del peso. Es importante señalar que este valor corresponde a una estimación en una etapa preliminar de diseño y se encuentra condicionado por las variables consideradas y por el modelo de predicción empleado.

```
1 plt.figure(figsize=(8,5))
2 plt.hist(df['Peso total (ton)'], bins=10, alpha=0.7)
3 plt.axvline(gbest_val, linestyle='--', label='Peso óptimo PSO')
4 plt.xlabel('Peso total (ton)')
5 plt.ylabel('Frecuencia')
6 plt.title('Distribución de pesos del dataset y solución PSO')
7 plt.legend()
8 plt.grid(True)
9 plt.show()
10
```




El valor óptimo obtenido mediante PSO no coincide necesariamente con un registro específico del conjunto de datos original, ya que el proceso de optimización se realiza sobre un espacio continuo de variables geométricas. En este sentido, la solución encontrada representa una configuración interpolada entre diseños existentes, estimada por la red neuronal, y no una repetición exacta de un caso

Comparación antes y después PSO (barras)

```

1 labels = ["Peso promedio", "Peso óptimo PSO"]
2 values = [peso_promedio, gbest_val]
3
4 plt.figure(figsize=(5,4))
5 plt.bar(labels, values)
6 plt.ylabel("Peso (ton)")
7 plt.title("Comparación de peso antes y después de PSO")
8 plt.grid(axis='y')
9 plt.show()

```



```

1 # --- ASIGNACION DE SECCIONES COMO OUTPUT ---
2
3 # Construimos un vector geométrico óptimo
4 geom_opt = pd.Series(gbest, index=psd_features)
5
6 # Medimos distancia con diseños reales
7 distancias = np.linalg.norm(
8     df[psd_features].values - geom_opt.values,
9     axis=1
10 )
11
12 # Tomamos el diseño más cercano
13 idx_mejor = np.argmin(distancias)
14
15 # Extraemos secciones asociadas
16 secciones_output = {
17     "Dimension de Cordon Sup/Inf": df.loc[idx_mejor, "Dimension de Cordon Sup/Inf"],
18     "Dim. Diag. S/I": df.loc[idx_mejor, "Dim. Diag. S/I"],
19     "Dim. Montante": df.loc[idx_mejor, "Dim. Montante"]
20 }
21

```

```

1 resultado_final = {}
2
3 # Geometría óptima
4 for i, f in enumerate(psd_features):
5     resultado_final[f] = round(gbest[i], 2)
6
7 # Secciones estructurales
8 resultado_final.update(secciones_output)
9
10 # Peso
11 resultado_final["Peso óptimo estimado (ton)"] = round(gbest_val, 2)
12
13 pd.DataFrame(resultado_final)
14

```

	Altura (m)	Nº Paneles	Ancho de Puente (m)	Sep Vigas Longitudinales (m)	Dimension de Cordon Sup/Inf	Dim. Diag. S/I	Dim. Montante	Peso óptimo estimado (ton)
0	5.5	6.0	11.8	2.1	400x410x19.0	380x390x18.0	200x200x12.5	139.059998

Capítulo 5

RESULTADOS Y DISCUSIÓN

En este capítulo se presentan los principales resultados obtenidos a partir del modelo de red neuronal y del proceso de optimización mediante PSO aplicados al diseño preliminar de puentes reticulados.

La red neuronal entrenada logró reproducir adecuadamente la relación entre las variables geométricas del puente y su peso estructural. Al comparar los valores reales con los valores estimados, se observó una buena concordancia general, lo que indica que el modelo es capaz de capturar las tendencias principales del conjunto de datos. Esto permitió utilizar la red como una función objetivo confiable dentro del proceso de optimización.

El comportamiento del entrenamiento mostró una convergencia estable, sin diferencias significativas entre las curvas de entrenamiento y validación. Esto sugiere que el modelo no memoriza los datos, sino que aprende una relación general entre geometría y peso, lo cual es fundamental para su uso en un proceso iterativo como el PSO.

En cuanto a la optimización, el algoritmo PSO permitió identificar una configuración geométrica con un peso estimado inferior al promedio del conjunto de datos. La convergencia se produjo en pocas iteraciones, lo cual está directamente relacionado con el hecho de que solo un número limitado de variables fue optimizado y que el modelo predictivo presenta una respuesta suave. Por esta razón, la gráfica de convergencia muestra una rápida estabilización del valor óptimo.

Es importante destacar que el peso obtenido no representa un valor absoluto mínimo del conjunto de datos, sino un diseño óptimo condicionado por las variables fijadas por el usuario. Por lo tanto, el resultado debe interpretarse como una alternativa eficiente dentro de un proceso de diseño preliminar.

Finalmente, a partir de la geometría optimizada se asignaron secciones estructurales utilizando diseños reales del conjunto de datos, lo que permitió obtener una solución coherente desde el punto de vista constructivo.

Capítulo 6

CONCLUSIONES Y RECOMENDACIONES

6.1. Conclusiones

En este trabajo se desarrolló una metodología que integra aprendizaje automático y optimización bioinspirada para apoyar el diseño preliminar de puentes reticulados. Se logró entrenar una red neuronal profunda capaz de estimar el peso estructural con un nivel de precisión adecuado, lo que permitió su uso como modelo sustituto dentro del proceso de optimización.

La optimización mediante PSO permitió identificar configuraciones geométricas que conducen a reducciones significativas del peso estructural estimado respecto al promedio del conjunto de datos. En el caso analizado, la solución óptima alcanzó una disminución del orden del 55 %, lo que refleja la capacidad del método para explorar combinaciones de variables poco frecuentes en los diseños históricos, manteniéndose dentro del dominio aprendido por el modelo predictivo. Este resultado debe interpretarse como una estimación preliminar, condicionada por las variables consideradas y las restricciones impuestas. En conjunto, los resultados obtenidos confirman la viabilidad del enfoque propuesto como una herramienta de apoyo en etapas tempranas de diseño estructural, permitiendo evaluar alternativas de forma rápida y sistemática.

Finalmente, la metodología propuesta permite integrar información histórica de diseño con técnicas modernas de optimización, facilitando la exploración de alternativas estructurales de manera eficiente.

6.2. Recomendaciones

- Ampliar el conjunto de datos para incluir una mayor variedad de diseños y mejorar la robustez del modelo.
- Incorporar más variables estructurales y restricciones técnicas para acercar el modelo a un diseño de detalle.
- Evaluar otras técnicas de optimización y comparar sus resultados con los obtenidos mediante PSO.
- Utilizar la metodología como una herramienta de apoyo, complementaria a los métodos tradicionales de análisis estructural.

Bibliografía

- [1] Salmon, C. G., Johnson, J. E., & Malhas, F. A. (2009). *Steel Structures: Design and Behavior*. Pearson.
- [2] Chen, W. F., & Duan, L. (2014). *Bridge Engineering Handbook*. CRC Press.
- [3] Ghavami, K. (2008). *Optimal Design of Truss Structures*. Springer.
- [4] Kaveh, A. (2014). *Advances in Metaheuristic Algorithms for Optimal Design of Structures*. Springer.
- [5] Forrester, A. I. J., Sóbester, A., & Keane, A. J. (2008). *Engineering Design via Surrogate Modelling: A Practical Guide*. John Wiley & Sons.
- [6] Bendsøe, M. P., & Sigmund, O. (2003). *Topology Optimization: Theory, Methods and Applications*. Springer.
- [7] Kennedy, J., & Eberhart, R. (1995). Particle swarm optimization. *Proceedings of the IEEE International Conference on Neural Networks*, pp. 1942–1948. <https://doi.org/10.1109/ICNN.1995.488968>
- [8] Hibbeler, R. C. (2017). *Structural Analysis*. Pearson Education.
- [9] Rozvany, G. I. N. (2009). A critical review of established methods of structural topology optimization. *Structural and Multidisciplinary Optimization*, 37(3), 217–237.
- [10] Achtziger, W., & Stolpe, M. (2007). Truss topology optimization with discrete design variables. *Structural and Multidisciplinary Optimization*, 33(1), 15–30. <https://doi.org/10.1007/s00158-006-0063-5>
- [11] Adeli, H., & Panakkat, A. (2009). A probabilistic neural network for earthquake magnitude prediction. *Neural Networks*, 22(7), 1018–1024. <https://doi.org/10.1016/j.neunet.2009.04.007>
- [12] Bathe, K. J. (1996). *Finite Element Procedures*. Prentice Hall.

- [13] Chen, Y., Liu, Z., Sun, H., & Wang, Z. (2021). Graph neural networks for structural performance prediction. *Engineering Structures*, 246, 113032. <https://doi.org/10.1016/j.engstruct.2021.113032>
- [14] Clerc, M., & Kennedy, J. (2002). The particle swarm—Explosion, stability, and convergence in a multidimensional complex space. *IEEE Transactions on Evolutionary Computation*, 6(1), 58–73. <https://doi.org/10.1109/4235.985692>
- [15] Cook, R. D., Malkus, D. S., Plesha, M. E., & Witt, R. J. (2007). *Concepts and Applications of Finite Element Analysis* (4th ed.). Wiley.
- [16] Farrar, C. R., & Worden, K. (2012). *Structural Health Monitoring: A Machine Learning Perspective*. Wiley.
- [17] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [18] McNeel, R. (2023). *Grasshopper: Generative Modeling for Rhino (Software Documentation)*. Robert McNeel & Associates. <https://www.grasshopper3d.com>